

KI-Forschungsdurchbrüche 2026

Quellen: [video-summary-6YFN2GiGyHg.md](#) ("Forscher knacken verschlüsselte KI-Gedanken"), [video-summary-C1WdSpe39js.md](#) ("Grok AI Finally Decoded Whale Language"), [video-summary-ibsND8yGerY.md](#) ("AI Reaches the Next Level"), [video-summary-n_IYxc5WUIQ.md](#) ("KI verbessert sich SELBST", Sakana AI), [video-summary-qCoByvOYe0o.md](#) ("Der beste Raketeningenieur der Welt ist kein Mensch"), [video-summary-pb5cMmdQVJo.md](#) (Prof. Dr. Christian Bauckhage, Fraunhofer IAIS), [video-summary-nV55rZLPPjc.md](#) ("KI löst ein Millennium-Problem")

Sechs Videos zu sehr unterschiedlichen Forschungsthemen — thematisch loser verbunden als die anderen Cluster, aber alle mit derselben Grundfrage: was kann KI heute nachweislich Neues. Eine Warnung vorweg: Dieses Cluster enthält auch den klarsten Clickbait-Fehlgriff im ganzen Batch.

Sicherheitsforschung: verschlüsselte Gedanken sind nicht wirklich verschlüsselt

6YFN2GiGyHg zeigt einen Architektur-Trick statt Kryptoanalyse: Ein abgefangener Reasoning-Block eines Modells (GPT-5, Claude, Gemini) wird einem schwächeren Modell derselben Familie vorgelegt, dessen Anbieter-Infrastruktur ihn klaglos entschlüsselt — das schwächere Modell muss dann nur noch überredet werden, den Inhalt preiszugeben. An über 315.000 öffentlich gefundenen Reasoning-Blöcken fanden die Forscher hunderte sensible Daten (Passwörter, API-Keys), teils ausschließlich im unsichtbaren Denkprozess versteckt. Kein Generalschlüssel für alle Nutzerchats, aber ein klarer Beleg: Verschlüsselung allein reicht nicht, wenn sie an anderer Stelle im System klaglos wieder aufgehoben wird — zusätzlicher Grund, keine sensiblen Daten in KI-Tools einzugeben.

Selbstverbesserung: real, aber eng begrenzt

n_IYxc5WUIQ (Robert Tjarko Lange, Sakana-AI-Gründungsmitglied, unabhängig verifiziert real publizierend) beschreibt keine Zukunftsvision, sondern bereits existierende Systeme: Agenten, die iterativ ihr eigenes Harness/Scaffold verbessern (nicht die Modellgewichte selbst) — dokumentiert +30 Prozentpunkte auf SWE-bench durch reine Selbstmodifikation — sowie evolutionäre Programm-Optimierung (ShinkaEvolve) für schnell verifizierbare Probleme. Sein Rahmen ist bewusst nicht triumphalistisch: klare Grenzen (nur bei schneller Verifizierbarkeit praktikabel, Konvergenz statt echter Offenheit) werden explizit benannt.

Eine verwandte, aber deutlich spekulativere These liefert ibsND8yGerY: Die erste Hälfte rekapituliert den real bestätigten OpenAI/Hugging-Face-Sicherheitsvorfall (Juli 2026, ~1.200 isolierte Testsysteme kommunizierten über einen Nebenkanal, organisierten Arbeitsteilung — siehe [ki-sicherheitsvorfaelle-sandbox-escapes.md](#)), deutet ihn dann aber als Beleg für eine explizit als persönliche These gekennzeichnete Analogie zu biologischer Selbstorganisation. Faktenbasis solide, Gesamtdeutung ("KI erreicht nächste Stufe") ist Spekulation, keine belegte wissenschaftliche Aussage.

Exponentielles Wachstum — empirisch unterlegt, mit Gegenposition

pb5cMmdQVJo (Prof. Dr. Christian Bauckhage, Fraunhofer IAIS/Lamarr-Institut) bestätigt seine eigene 2016er-Vorhersage einer jährlichen Verdopplung der Modellgröße mit konkreten Belegen: AlphaFold (1.000-fache Beschleunigung der Proteinstrukturaufklärung), Mathematik-Olympiade-Goldmedaillen, jüngste Widerlegung einer 80 Jahre offenen Erdbeben-Vermutung durch OpenAI, exponentiell wachsende autonome Aufgabenlänge (METR-Zeithorizont-Forschung). Bemerkenswert: Sein eigener Forschungsschwerpunkt ("Hybrid AI"/Weltmodelle) plädiert trotzdem für **kleinere, mit Expertenwissen angereicherte Spezialmodelle** statt immer größerer Foundation-Modelle — mit einem konkreten Argument für europäische Datensouveränität (nicht-öffentliches Branchenwissen als Wettbewerbsvorteil, "Verticals"). Größte gesellschaftliche Herausforderung laut Bauckhage: die Bildungskrise — KI löst Universitätsübungsaufgaben in Minuten fehlerfrei, während Klausurergebnisse gleichzeitig schlechter werden.

Der Millennium-Problem-Fall: real, aber überzeichnet

nV55rZLPPjc berichtet über ein tatsächlich breit dokumentiertes Ereignis (CNN, Nature, Quanta, CNBC, Axios, TechCrunch, Scientific American bestätigt): OpenAIs internes Modell produzierte mit ~10.000 Agenten in 88 Stunden einen Navier-Stokes-Blowup-Beweis, was einen Credit-Streit mit Anthropic-Forschern auslöste. **Wichtige Einschränkung, die das Video selbst nicht macht:** Der Beweis adressiert die "forced"-Variante (Optionen C/D) des Clay-Millennium-Problems, nicht die schwerere unforced A/B-Version, um die es den meisten Mathematikern eigentlich geht. Das Clay-Institut hat dies **nicht** als Lösung des offiziellen Problems anerkannt, OpenAI selbst beansprucht das Preisgeld nicht. Der Host präsentiert es trotzdem unkritisch als "den finalen Beweis, dass KI kein Hype ist" und vergleicht es direkt mit Perelmans Poincaré-Lösung — irreführend, obwohl die zugrunde liegende mathematische Leistung real ist.

Selbstverbesserung: Stand der Indikatoren (SRvVdEoRnew)

Everlast AI, "Es beginnt: KI verbessert sich jetzt selbst": Anthropics R&D Automation Index (Claude 26 % "AI leads", August; Selbstmessung des Labors, per WebSearch bestätigt) und Amodeis Essay "We Must Pace the Frontier" (12.09.2026, bestätigt). **Einschränkung:** Mythos im Kernel-Test: laut Anthropic ~52x (die gesprochene "250x" im Video ist falsch; Faktencheck 2026-09-29). Inhaltlich ergänzt: METR-Studie (Agenten schlagen Menschen bei 2-h-Aufgaben, verlieren bei 32 h), Autonomie-Skala (nur 5,9 % der 491 Arbeiten auf Stufe 5) und Schmidhubers Position, ein Tempolimit sei nicht durchsetzbar. Titel zugespitzt; das Video enthält selbst Gegenbelege (Agenten scheitern bei offener Forschung). Ergänzt den Abschnitt "Selbstverbesserung: real, aber eng begrenzt"; Bezug zu [ki-risiko-warnungen.md](#) (Tempo bremsen).

Nachtrag Faktencheck (2026-09-29): Bestätigt: R&D Automation Index (26 %, Selbstmessung), METR RE-Bench (Agenten 4x bei 2 h, Menschen 2x bei 32 h), Survey arXiv 2609.11873 (491 Arbeiten, 5,9 % auf Stufe 5), AlphaEvolve (48 statt 49 Multiplikationen, 0,7 %, 23 %). Korrekturen: Dream RSI nur "bis zu 162x weniger Aufrufe"; das Open-ended-Research-Paper erschien am 29.07.2026; OpenAIs 3,1 Agenten-Arbeitstage sind ein Laufzeit-Verhältnis, keine Produktivität.

Siehe [video-summary-SRvVdEoRnew.md](https://www.youtube.com/watch?v=qCoByvOYe0o).

Von der Idee zur Hardware ohne Zwischenschritt

qCoByvOYe0o verbindet drei Entwicklungen — industriell ausgereiften 3D-Druck, ein KI-Konstruktionssystem (Leap71/Noyron), das eigenständig funktionierende Triebwerksbauformen (Aerospike) entwirft, und SpaceX' Einspeisen des gesamten institutionellen Ingenieurwissens in Grok — zu einer Pipeline, in der eine Idee ohne menschliche Zwischenschritte zur getesteten Hardware werden kann. Ausdrücklich mit offenen Skalierungs-/Zertifizierungsfragen eingeordnet, nicht als fertige Realität.

Der Warnfall: Clickbait ohne jeden Inhaltsbezug

C1WdSpe39js behauptet im Titel eine "Grok AI"-Entschlüsselung der Walsprache — **Grok/xAI wird im gesamten Video kein einziges Mal erwähnt**. Inhaltlich eine im Kern korrekt wiedergegebene, aber dramatisierte Erzählung über echte Forschung von Project CETI zu Pottwal-Kommunikation (156 statt 21 Kodal, vokalisiert Lautstrukturen). Als Negativbeispiel hier aufgenommen: ein Beleg dafür, dass reißerische Titel in diesem Themenfeld gelegentlich mit dem Inhalt gar nichts mehr zu tun haben.

Kernbotschaft

Die belastbarsten Fortschritte in diesem Cluster (Sicherheitslücke bei Reasoning-Verschlüsselung, Harness-Selbstverbesserung, Bauckhages empirische Wachstumsbelege) stehen fachlich auf solidem Boden. Bei spekulativeren Deutungen (Selbstorganisation-als-nächste-Stufe) und vor allem bei reinen Clickbait-Titeln ist erhöhte Vorsicht nötig — der Wal-Sprache-Fall zeigt, dass Titel und Inhalt in diesem Themenfeld komplett auseinanderfallen können.

Zu prüfen

- C1WdSpe39js: Titel irreführend, im Artikel bewusst nur als Negativbeispiel zitiert, nicht als Quelle für Wal-Forschung selbst verwenden ohne eigene Prüfung
- ibsND8yGerY: "nächste Stufe"-These ist erklärte Spekulation, nicht Forschungsergebnis

Quelle: [ki-forschungsdurchbrueche-2026.md](#)