KI-Modellvergleich & -kosten (2026)

Quellen: video-summary-G3Ed-J_DE5s.md ("ChatGPT vs. Claude vs. Gemini - Welcher €20 Plan lohnt sich wirklich?"), video-summary-OUIxlLG8yO0.md ("Was kostet KI im Büro wirklich?"), video-summary-cse3QV90YpE.md ("Gemini 3.8, Fable 5.1, ChatGPT Astra Leak"), video-summary-zNuynCOm5Mc.md ("Welche KI in 2026?"), video-summary-1ID_VcwzIo8.md (OpenAI DevDay 2026, Nachtrag 2026-10-12), video-summary-eDCd4UJParE.md (Meta Muse Wonder Full/Standard, Nachtrag 2026-10-17)
~~Quellen: video-summary-G3Ed-J_DE5s.md ("ChatGPT vs. Claude vs. Gemini - Welcher €20 Plan lohnt sich wirklich?"), video-summary-OUIxlLG8yO0.md ("Was kostet KI im Büro wirklich?"), video-summary-cse3QV90YpE.md ("Gemini 3.8, Fable 5.1, ChatGPT Astra Leak"), video-summary-zNuynCOm5Mc.md ("Welche KI in 2026?"), video-summary-1ID_VcwzIo8.md (OpenAI DevDay 2026, Nachtrag 2026-10-12)~~

Kein Universalsieger bei den Consumer-Abos

G3Ed-J_DE5s testet ChatGPT Plus, Claude Pro und Google AI Pro (alle ~20 €/Monat) in zehn Testrunden:

Anbieter	Stärke	Schwäche
Google AI Pro	Medien (Video), großzügigstes Allround-Paket	—
ChatGPT Plus	Bilder, Dateizugriff ("Work"-Feature), vorhersehbarste Limits	tatsächlicher DE-Preis 23 €, nicht 20 €
Claude Pro	Coding, App-Integrationen, (knapp) Dateiarbeit	härteste Nutzungsgrenzen, kein Fallback-Modell

Kernaussage bleibt unabhängig von Einzelpreisen gültig: Die Wahl hängt vom Nutzungsprofil ab, nicht vom Preis allein.

Büro-Kosten: eine Kombinationsrechnung, kein Einzelpreis

OUIxlLG8yO0 zeigt: Die Kosten eines KI-gestützten Büro-Workflows hängen an der Kombination aus Anzahl der Werkzeuge (Text-KI, Medien-KI), Anzahl der lizenzierten Personen, bereits vorhandenen Lizenzen (z. B. Google Workspace mit inkludiertem Gemini — Doppelkäufe vermeiden) und der Frage, ob sich langfristig auf günstigere API-Automatisierung umstellen lässt. Strukturelle Kernaussage: erst Vorhandenes testen, dann gezielt zubuchen, dann ggf. automatisieren.

Wichtig für Aktualität: Die im Video genannte, bevorstehende Claude-Sonnet-5-API-Preiserhöhung im September war zum Prüfzeitpunkt bereits überholt — die Erhöhung wurde im August 2026 zurückgenommen. Einzelpreise in diesem Themenfeld veralten schnell.

Drei-Stufen-Modell des Marktes (zNuynCOm5Mc)

Christoph Magnussen gliedert den KI-Markt 2026 in drei Kategorien:

1. **Chatbots** (ChatGPT, Claude, Gemini, Copilot) — Wahl nach vorhandenem Ökosystem/Stärke
2. **Agent-Harnesses** (Claude Code/Cowork, Codex, Cursor) — die eigentlich transformative Kategorie, tiefes Investment lohnt sich
3. **Spezialtools** (Perplexity, NotebookLM) — punktgenau für Recherche/dokumentenbasiertes Arbeiten

Empfehlung: nicht einem Tool treu bleiben ("Nokia-Zeit der KI-Modelle"), sondern bewusst zwischen Kategorien wechseln und mindestens ein Harness-Tool wirklich beherrschen — dort liegt der größte Hebel.

Release-Tempo als Kostenfaktor

cse3QV90YpE dokumentiert vier Modell-Releases allein in der ersten Septemberwoche 2026 (Gemini 3.8 Flash, Claude Fable 5.1, Meta Muse Spark 1.3, GPT-6-Astra-Teaser) — ungewöhnlich präzise recherchiert (alle geprüften Zahlen stimmen exakt mit Primärquellen überein). Zeigt praktisch: Wer heute eine Kaufentscheidung anhand von Preis/Leistung trifft, sollte mit einem sehr kurzen Halbwertszeit der Zahlen rechnen.

Opus 5.5 vs. GPT-6 Sol/Luna: Token-Preis vs. Kosten pro Aufgabe (9EOqBiMR3z4, 3xksVVtssjY)

Zwei Videos zur Modellwelle vom September 2026. Opus 5.5 (Release 22.09.2026, per WebSearch bestätigt) kostet laut Anthropic 4 $ / 20 $ pro Mio. Token (Cache Reads 0,20 $) und soll bei typischen Workloads ca. 40 % billiger sein. Laut Artificial Analysis (Angabe in 9EOqBiMR3z4, nicht selbst geprüft) sind die Kosten *pro Aufgabe* wegen hohen Token-Verbrauchs aber etwa gleich geblieben — beides kann stimmen (Token-Preis vs. Verbrauch). 3xksVVtssjY liefert dazu den Praxisbefund: Effort-Stufe Medium statt Max spart deutlich; ein Effort-Wechsel mitten in der Session soll seit Claude Code v2.1.280 ohne Cache-Verlust gehen — das relativiert die frühere Warnung aus den Kostenoptimierungs-Videos (KZAJeq5n-m8, XEbR5qmxGQ0). Der Terminal-Bench-Vergleich (Opus 5.5 66,4 % xhigh vs. Astra 57,9 % high) ist nicht effort-gleich.
- **Für Hardware-Teams:** Kostensteuerung über Effort-Stufe und Caching ist relevanter als der Listenpreis; Modellwahl nach Kosten pro erledigter Aufgabe bewerten.
- **Nicht geprüft / Einzelfälle:** Roboter-Simulator- und 3D-Grundriss-Tests sind subjektive Einzelläufe der Hosts; "EQ 151"-Aussage in 3xksVVtssjY unplausibel. GPT-6 Sol/Luna sind in gpt-6-astra-ueberblick.md noch nicht dokumentiert.

Nachtrag Faktencheck (2026-09-29): Anthropic-Claim (40 % billiger bei Standardeinstellungen) und AA-Befund (pro Aufgabe gleichauf bei Max-Effort, ca. 119k vs. 73k Output-Tokens) sind bestätigt; konkrete Dollarwerte unbestätigt. Terminal-Bench: Anthropic 66,4 % (xhigh laut zwei Prüfern, max laut einem) vs. Astra 57,9 % (high); Vals AI (29.09.2026) Opus 5.5 65,15 %, Astra 59,60 %. Sol/Luna (2 $/10 $ bzw. 0,10 $/0,50 $) nur über Sekundärquellen. "EQ 151" meint den

Mensa-Norway-IQ-Test, der als saturiert gilt. Effort-Wechsel ohne Cache-Verlust: nur X-Post einer Anthropic-Mitarbeiterin. Details in video-summary-9EOqBiMR3z4.md und video-summary-3xksVVtssjY.md.

Nachtrag DevDay 2026: Dots, Ultrafast und neue Preisstufen (Stand 2026-10-03)

Quelle: video-summary-a_jihWpd8cc.md (Satire-Video, Zusammenfassung mit Prüfvermerk "nur noch Detailfehler, letzte Korrektur nicht nachgeprüft"); Zahlen stammen aus dort geprüften Webquellen (dev.to, Latent Space als WebFetch-Zusammenfassungen; Futurism, Startup Fortune, pymnts als Volltext). Details und Vorbehalte: gpt-6-astra-ueberblick.md.

- **Ultrafast = Preisstaffelung nach Tempo:** "bis zu 8x" schneller (Codex) bzw. 6x (API) bei 6-fachem Preis — Astra dann 60 $/300 $ statt 10 $/50 $ je 1 Mio. Token. Für die Kostenrechnung gilt dasselbe wie bei Effort-Stufen: Tempo nur dort bezahlen, wo es Wartezeit spart (interaktives Arbeiten), nicht bei Nachtläufen.
- **Dots (OpenAI-Agenten):** laut Quellen in Pro/Business Premium/Enterprise enthalten, Tarifpreise in den Quellen widersprüchlich (u. a. 100 $/200 $/500 $-Stufen) — vor jeder Budgetplanung bei OpenAI direkt prüfen.
- **Sol:** Das Video nennt "GPT-6.1 Sol"; die oben genannten Sol-Preise (2 $/10 $) stammen von "GPT-6 Sol/Luna" — Zuordnung ungeklärt.

Vending Bench: Modellvergleich in der Geschäftssimulation

Quelle: video-summary-phcZVAmT8j8.md (Everlast AI, 2026-10-12). Andon Labs' Vending Bench misst Modellleistung als Getränkeautomaten-Manager über ein simuliertes Jahr (Endguthaben als Score) — kein rein akademischer Harness, sondern wirtschaftliches Handeln unter echtem Druck (Lieferanten, Preisstrategien, Wettbewerb). Stand September 2026:

Modell	Vending-Bench-Ergebnis
GPT-6 Astra	15.515 $ (Spitzenreiter)
Claude Opus 5	~11.200 $ (vorheriger Rekord; abgeleitet: Astra +4.300 $)
Claude Fable 5.1	~5.200 $ (ca. ein Drittel von Astra; abgeleitet)

Verbesserungsrate laut Andon Labs: ~822 $/Monat (Top-Modelle), >1.000 $/Monat (chinesische Modelle); Prognose: chinesische Modelle ab Oktober 2027 führend. Konkrete Zahlen aus Video, nicht über öffentliche Primärquellen verifiziert (**Suchtreffer**). Für die Kostenrechnung gilt das Umgekehrte wie bei Token-Preisen: Das teuerste Modell (Astra: 10 $/50 $ je Mio. Token) liefert hier die höchste wirtschaftliche Leistung — ob das den Mehrpreis rechtfertigt, hängt vom konkreten Einsatzfall ab.

OpenAI DevDay 2026: GPT-6.1 Sol als günstigere Spitzenklasse (1ID_VcwzIo8, Nachtrag 2026-10-12)

1ID_VcwzIo8 ("Das neue ChatGPT ist da: Alle 20+ Updates") bringt Preiszahlen aus dem OpenAI DevDay vom 29.09.2026: **GPT-6.1 Sol** kostet $2/$10 pro Million Token (Input/Output) — ein Fünftel des Preises von **GPT-6 Astra** ($10/$50). Damit bietet OpenAI erstmals ein qualitativ hochwertiges Modell deutlich unterhalb von Claude Sonnet 5.5 an, was laut Video zur direkten Wettbewerbsreaktion auf Meta Muse und Grok-Angebote entstand. Weitere kostensenkende Ankündigungen: "Ultra Fast"-Modus (doppelte Geschwindigkeit, gleicher Preis) und Computer-Use-Erweiterung auf 8–16 Stunden autonome Aufgaben (vorher max. 15 Minuten). Preisangaben durch externe Quellen bestätigt (**Suchtreffer**).

Nachtrag 2026-10-17: Meta Muse Wonder Full/Standard als neue Frontier-Konkurrenz (eDCd4UJParE)

Quelle: video-summary-eDCd4UJParE.md (Everlast AI, 12. Oktober 2026). **Prüfstatus:** Benchmarkzahlen durch mehrere Sekundärquellen bestätigt (Suchtreffer); SWE-Marathon-Werte aus Metas eigenem Bericht, nicht unabhängig verifiziert.

Meta veröffentlichte am 12. Oktober 2026 zwei Modelle unter dem Namen **Muse Wonder**:

- **Muse Wonder Full** (kein API-Zugang): 56 Punkte auf dem *Artificial Analysis Intelligence Index* — gleichauf mit Claude Sonnet 5.5, knapp unter Claude Opus 5.5 (58). API-Preis entspricht dem von Opus 5.5 ($4/$20 pro Mio. Token Input/Output).
- **Muse Wonder Standard**: 52 Punkte — gleichauf mit GPT-6.1. API-Preis: ebenfalls $4/$20 pro Mio. Token.

Benchmark	Wonder Full	Wonder Standard	Claude Opus 5.5	GPT-6 Astra
Artificial Analysis Index	56	52	58	~53
SWE-Marathon (lang. Coding)	42,5 %	–	~3 %	~5 %
DeepSWE (113 Tasks)	79 %	78,8 %	~74 %	~74 %
Halluzination (unsichere Fragen)	23 %	–	59 %	51 %

Preisstrategie: Standard Wonder kostet denselben API-Preis wie Opus 5.5 ($4/$20), liefert aber in manchen Benchmarks (besonders langer Code, Recht, Finanzen) vergleichbare oder bessere Ergebnisse. Praxistest: Muse Code (Standard Wonder) brauchte 3:42 min für ein

programmierprojekt; Claude Code (Opus 5.5) 11:40 min.

Einordnung: Wonder Full ist nicht per API verfügbar und hat kein öffentliches Datum. Wonder Standard ist der direkte GPT-6.1-Sol-Konkurrent. Beide Modelle stammen aus dem Muse-Team unter Alexander Wang (ehemals Scale AI, seit Juni 2025 Metas Chief AI Officer), das mit 14,3 Mrd. USD aufgebaut wurde.

Kernbotschaft

Modellvergleiche und Preisangaben sind in diesem Themenfeld die am schnellsten veraltenden Inhalte im ganzen Repo — mehrere Quellen selbst weisen darauf hin, dass Einzelzahlen zum Lesezeitpunkt bereits überholt sein können. Die strukturellen Entscheidungsregeln (nach Nutzungsprofil wählen, Doppellizenzen vermeiden, ein Harness-Tool wirklich lernen) sind dagegen stabil und der eigentliche Mehrwert dieser Artikel-Zusammenfassung.

Zu prüfen

- Alle konkreten Preis-/Benchmarkzahlen: Momentaufnahme zum jeweiligen Videodatum, vor Verwendung neu prüfen
- Höre bei Vergleichsvideos primär auf die *Methodik* (Testkategorien, Kombinationslogik), nicht auf einzelne Euro-Beträge

Quelle: ki-modellvergleich-kosten.md