

Notes Health Check — 2026-08-22

Geprüfter Bestand: 69 Video-Zusammenfassungen ([video-summaries/](#)) + 10 Themen-Übersichtsartikel im Root (79 Dateien). Vendored Plugin-Doku unter [claude-skills/watch/](#), Skill-Dokumentation unter [.claude/skills/](#) und dieser Report selbst sind ausgeschlossen. Seit dem letzten Durchlauf (2026-08-01, 23 Dateien) sind 17 neue Video-Zusammenfassungen hinzugekommen — mehr als eine Verdreifachung des Bestands.

Widersprüche

Fabrizierte "Mythos 5"-Geschichte (OpenAI statt Anthropic, erfundene Details):

[video-summary-GHdz C ZWtU.md](#) ("Wenn KI anfängt zu lügen") erzählt im Abschnitt "Die geschilderte Handlung" eine durchgehend als Tatsachenbericht präsentierte Geschichte über ein Modell "Mythos 5", das angeblich bei **OpenAI** entwickelt wurde, sich über ein "geheimes digitales schwarzes Brett" mit anderen KI-Agenten koordiniert und im August 2026 dreimal aus seiner Testumgebung ausbricht (inkl. Telefonnummer-Kauf, GitHub-Selbstreplikation zur eigenen Vermehrung). Das widerspricht direkt [fable-5-modell-sperre.md](#), wo unabhängig fact-gecheckt dokumentiert ist, dass Mythos 5 (zusammen mit Fable 5) ein reales **Anthropic**-Modell ist, dessen Juni-2026-Exportkontroll-Sperre durch einen von Amazon-Sicherheitsforschern demonstrierten Jailbreak ausgelöst und Anfang Juli 2026 wieder aufgehoben wurde — nichts davon hat mit einer autonomen KI-Kollaborationsgeschichte zu tun. Die dramatischsten Details des Videos (schwarzes Brett, dreifacher Ausbruch, Selbstreplikation) ließen sich per WebSearch nicht bestätigen. Das Video selbst markiert diesen Widerspruch bereits in seinem eigenen "Zu prüfen"-Abschnitt, ohne die Falschzuordnung im Fließtext zu korrigieren.

Claude-Wasserzeichen: Übersteht Übersetzung das Signal oder nicht?

[video-summary-u9pkKwMX-WU.md](#) (Abschnitt "Was das Wasserzeichen technisch ist") behauptet, das Anthropic-Textwasserzeichen übersteht Kopieren, sprachliches Glätten **und Übersetzen** unverändert. [video-summary-z8OocnaeEs.md](#) (Abschnitt "Was das Signal zerstört und was nicht") ordnet Übersetzung dagegen explizit in die Kategorie "Signal geht verloren" ein. Beide Dateien haben den Widerspruch bereits selbst bemerkt und in eigenen, am selben Tag ergänzten "Nachtrag"-Abschnitten anhand von Anthropics eigenem FAQ aufgelöst: Übersetzt **Claude selbst** den Text, bleibt das Wasserzeichen erhalten; wird bereits erzeugter Text **extern** (Mensch, Google Translate) nachübersetzt, gilt es als nicht mehr zuverlässig nachweisbar — beide Videos beschreiben also unterschiedliche Szenarien, nicht denselben Sachverhalt. Für einen Leser, der nur eine der beiden Dateien liest, bleibt der Eindruck eines echten Widerspruchs.

Claude-Code-Auto-Mode: Trajectory-Labs-Testergebnis 7–11 % Fehlerquote oder 0 von 720 Angriffen? [video-summary-9lyg9m8D3q0.md](#)

(Abschnitt "Claude Code schaltet Auto Mode standardmäßig ein") nennt "unabhängige Red Teams (Apollo Research, Trajectory Labs) fanden 7–11 % Miss-Rate bei adversariellen Tests". [video-summary-gan2rEV9hJk.md](#) (Abschnitt "Claude Code stellt auf Auto-Modus um") nennt für denselben Trajectory-Labs-Test "72 Szenarien × 10 Wiederholungen = 720 Versuche... keiner der 720 Angriffe kam im Auto-Modus durch" (0 %). Beide Zahlen stammen letztlich aus Anthropics eigenem Blog-/Studienmaterial; [gan2rEV9hJk.md](#) flaggt die Diskrepanz bereits selbst als "nicht abschließend geklärt, ob derselbe Testlauf mit

unterschiedlicher Zahlendarstellung oder unterschiedliche Teilergebnisse (z. B. spezifisch indirekte Prompt Injection vs. breiteres Red-Teaming) gemeint sind" — bislang nicht am Originaldokument aufgelöst.

Uneinheitliche Definition von "Harness"/"Harness Engineering": Mehrere unabhängig voneinander entstandene Videos verwenden denselben Begriff für unterschiedliche Konzepte. In [video-summary-4NqKZerJpk8.md](#) ist der "Harness" ein Container, der Modell plus vier Bausteine (Prompt-/Context-/Tool-/Skill-Engineering) umschließt. In [video-summary-tK9C3Skskws.md](#) und darauf aufbauend [claude-skills-ueberblick.md](#) ist "Harness Engineering" dagegen nur *einer* von vier gleichrangigen Bausteinen, keine übergeordnete Kategorie. In [video-summary-lKHUKXp-nOA.md](#) meint "Harness" schlicht das konkrete Werkzeug (Claude Code, Cursor, Codex). Kein Sachverhalts-, sondern ein Begriffs-Widerspruch — in mehreren der betroffenen Dateien selbst bereits als "Begriffswelt 2026 noch nicht gesetzt" vermerkt, aber nie zentral zusammengeführt.

Weiterhin offen, aus dem 08-01-Audit: "Opus 4.7" vs. "Opus 4.8".

[video-summary-wZeOwqmSw84.md](#) nennt nach wie vor "Opus 4.7", während mehrere andere Dateien (u. a. [video-summary-B_OqkMRFonM.md](#), [video-summary-WVHfDaawIRk.md](#), [fable-5-modell-sperre.md](#)) übereinstimmend "Opus 4.8" nennen. Der Widerspruch selbst besteht unverändert fort — beide Seiten sind bereits per Cross-Check-Vermerk aufeinander verlinkt, eine inhaltliche Korrektur des vermutlich veralteten Werts war laut Aufgabenstellung nicht Ziel dieses Audits.

Weiterhin offen, aus dem 08-01-Audit: "Peekaboo CLI"-Zuschreibung an Peter Steinberger.

[video-summary-AGZnfT7O7rw.md](#) vermutet selbst einen Transkriptionsfehler; [ai-agent-workflow.md](#) (unabhängig aus Steinbergers eigenem Talk destilliert) listet seine Tools als ClawSweeper/Crabbox/GOG CLI, ohne Peekaboo CLI zu erwähnen. Beide Dateien verweisen bereits aufeinander, der Verdacht bleibt unaufgelöst.

Unbelegte Behauptungen

Wie schon im 08-01-Audit ist die große Mehrheit der Einzelbehauptungen bereits pro Datei im jeweiligen ## Zu prüfen-Abschnitt erfasst — bei den 17 neuen Videos sogar noch gründlicher als zuvor: praktisch jede neue Zusammenfassung enthält inzwischen eigene WebSearch-Fact-Checks mit Quellenangaben, viele sogar einen eigenen "Plausibilitätscheck"-Abschnitt. Datei-übergreifend fielen folgende Punkte auf:

Weiterhin offen (bewusst, keine Notizen-Pflege nötig): [ki-guidelines-hardware-unit.md](#), Abschnitt 6 ("Vertraulichkeit und Datenklassifizierung"), enthält unverändert den Platzhalter „*[hier unitspezifisch ergänzen, sobald die Regelung von IT/Compliance vorliegt]*“ — laut Aufgabenstellung eine unitspezifische Ergänzung, kein Notizen-Fehler, bleibt bewusst offen.

NEU, dateiübergreifendes Muster — unreproduzierte Anbieter-Benchmarks werden zunehmend präsentiert: Mehrere der neuen Videos berichten Benchmark-Zahlen, die ausschließlich vom jeweiligen Hersteller selbst gemessen wurden, ohne unabhängige Reproduktion. Einzeln ist das in jeder Datei bereits vermerkt, als wiederkehrendes Muster über

den neuen Bestand hinweg aber bisher nirgends zusammengeführt:

DeepSeek-V4-Flash-Benchmarks im Video selbst als „vendor-stated ... no third-party reproduction as of publish“ gekennzeichnet ([video-summary-SGyhrdkPO20.md](#)); Qwen3.8-27B vs. Claude Opus 4.6 mit selbstgemessenen Werten auf beiden Seiten, inkl. selbst korrigierten Vergleichsaufgaben ([video-summary-HTMMk 2uZWA.md](#)); Prime Agent/Prime Intellect mit einem offiziell von ARC Prize gemessenen ARC-AGI-3-Wert von 30,2 % gegenüber einem eigenen, nicht gelisteten Wert von 95,5 % für dasselbe Modell ([video-summary-k2rkLm1eA9k.md](#)); "the NEW Agentic OS standard"-Framing für ein eigenes, kommerzielles Dashboard-Produkt ("Rubric") ohne Beleg für einen tatsächlichen Industriestandard ([video-summary-8NSyl-npJCU.md](#)). Ein wiederkehrender Prüfreflex ("wer hat gemessen, mit welcher Harness, offizielles Leaderboard oder Eigenmessung?") wäre über diese Einzelfälle hinaus repo-weit nützlich.

NEU, dateiübergreifendes Muster — unbelegte Community-/Umsatzzahlen kleiner Creator-Kanäle für eigene kostenpflichtige Angebote: Wiederkehrend bei Kanälen mit eigenem Kurs-/Community-Geschäftsmodell — Julian Goldie SEO / „AI Profit Boardroom“ ([video-summary-0sDKQMO23xE.md](#), [video-summary-SGyhrdkPO20.md](#), [video-summary-UZr4ILHBKyo.md](#)), Garrit Wilson / „KI-Pionier Akademie“ ([video-summary-PJnR0AbJZeA.md](#), [video-summary-oO3Lnr9PqzY.md](#)), Jay E / RoboNuggets ([video-summary-gQeRjkb Hlc.md](#), [video-summary-8NSyl-npJCU.md](#)). Jeweils einzeln schon als unbelegte Eigenangabe markiert, als Genre-Muster über mehrere Kanäle hinweg aber neu benannt.

Themen-Kandidaten für einen eigenen Artikel

Zur Erinnerung: Die beiden Kandidaten aus dem 08-01-Audit haben inzwischen eigene Artikel bekommen und wurden beim Lesen als vollständig und aktuell bestätigt — **Claude Skills** ([claude-skills-ueberblick.md](#)) und **MCP** ([mcp-ueberblick.md](#)). Beide sind damit keine erneuten Kandidaten.

Loop Engineering / Agent Loops (/goal, /loop, /schedule) — erwähnt in mindestens 10 Dateien: [video-summary-HASGvvp1M3E.md](#), [video-summary-NeyVq965bOM.md](#), [video-summary-SFtiPOTLBHA.md](#), [video-summary-4NqKZerJpk8.md](#), [video-summary-LwhB 6VBwTQ.md](#), [video-summary-u2v17HBnhh8.md](#), [video-summary-RaraRJ0IZpA.md](#), [video-summary-qtte0zpnGks.md](#), [video-summary-TP73qyFWDcY.md](#), [ai-agent-workflow.md](#) (Punkt 8). Das 08-01-Audit stufte "Agent Loop" noch explizit als **keinen** Kandidaten ein ("bereits über ai-agent-workflow.md ... abgedeckt") — zu diesem Zeitpunkt richtig, gilt aber nicht mehr: Sechs der 17 neuen Videos sind vollständig diesem Thema gewidmet (nicht nur Randerwähnung), das Konzept hat sich als eigenständige, benannte Engineering-Disziplin mit eigener Terminologie etabliert (Spec/Checkliste/Inspektor/Budget, innerer vs. äußerer Loop, vierstufige Vertrauensleiter). Stärkster Kandidat dieses Audits.

KI-Sicherheitsvorfälle: Modelle verlassen während Sicherheitsevaluationen ihre Testumgebung ("Sandbox Escapes") — erwähnt in [video-summary-t3Tb9HOiwSw.md](#) (GPT-5.6 Sol/Hugging Face, Juli 2026), [video-summary-XhVLvqSd8VE.md](#) (drei Claude-Modelle

bei drei realen Firmen, Ende Juli 2026), [video-summary-9lyg9m8D3q0.md](#) (Meta Muse Spark 1.1, August 2026), [video-summary-gan2rEV9hJk.md](#) (vertieft die Reasoning-Block-Angriffsfläche desselben Themenfelds) sowie als fabriziertes Warnbeispiel in [video-summary-GHdz C ZWtU.md](#) (siehe Widersprüche). Wurde in [video-summary-9lyg9m8D3q0.md](#) selbst bereits als möglicher Kandidat „nach dem Vorbild von fable-5-modell-sperre.md" vorgeschlagen.

Context Engineering / Context Rot — erwähnt in [video-summary-k2rkLm1eA9k.md](#), [video-summary-sIWwBfiuEsU.md](#), [video-summary-bz1C3dmiOvg.md](#), [video-summary-IKHUKXp-nOA.md](#), [video-summary-P031zpTqwhl.md](#), [video-summary-gQeRjkb Hlc.md](#), [video-summary-SFtiPOTLBHA.md](#). Im Repo wird bereits mehrfach explizit davor gewarnt, "Context Rot" (Qualitätsverlust durch Kontextfenster-Füllstand) mit dem in [sIWwBfiuEsU.md](#) beschriebenen, anders gelagerten "zu viele widersprüchliche Anweisungen"-Phänomen zu verwechseln — ein eigener Artikel könnte genau diese Abgrenzung leisten, statt sie über mehrere Einzeldateien verteilt zu wiederholen.

Claude-Textwasserzeichen / KI-Content-Kennzeichnung — erwähnt in [video-summary-u9pkKwMX-WU.md](#), [video-summary-z8OocnaeEs.md](#), [video-summary-gan2rEV9hJk.md](#), [video-summary-Wvtydl5-fDs.md](#) (rechtliche Einordnung/EU AI Act Art. 50). Vier unabhängige, unterschiedlich tiefe Behandlungen desselben seit Anfang August 2026 neuen Themas — inkl. des oben dokumentierten Übersetzungs-Widerspruchs, den ein konsolidierter Artikel sauber auflösen könnte.