"ChatGPT Dots sind da: GPT-6.1 Sol, Decisions API und mehr"

Kanal: Kris • AI2ROI (deutschsprachiger KI-News-Kanal; Zusammenschnitt aus OpenAI-DevDay-Keynote-Ausschnitten und Sprecherkommentar)
~~**Kanal:** Kris • AI2ROI (deutschsprachiger KI-News-Kanal; ernsthafte Nachrichtenzusammenfassung mit Ausschnitten der OpenAI-Keynote, keine Satire)~~
URL: https://www.youtube.com/watch?v=A4lIdVtVBeg
Länge: 6:05 (hochgeladen 29.09.2026; die Beschreibung wurde laut Text später mit Stand 30.09.2026 ergänzt)
Zusammenfassung erstellt: 2026-10-04 (Fassung anderer Rechner), 2026-10-10 (Fassung dieser Session), zusammengeführt 2026-10-11
Prüfstatus: Zusammengeführt aus zwei Fassungen. Die Grundlage (Fassung vom 10.10.) wurde in 3 Prüfdurchläufen geprüft, die Zusammenführung anschließend einmal unabhängig (nur Detailfehler gefunden); die letzte Korrektur wurde nicht mehr nachgeprüft.
~~**Länge:** 6:05 (laut Metadaten 365 Sekunden), veröffentlicht 29.09.2026~~
~~**Zusammenfassung erstellt:** 2026-10-04~~

Hinweis zum Ablauf: Die YouTube-Untertitelspur war vorhanden (kein Whisper nötig), ist aber englisch beschriftet, obwohl der Kanal deutsch spricht. Sie ist vermutlich eine maschinelle Übersetzung des deutschen Sprechtextes; Hinweise darauf sind Verhörer wie "Soll" statt "Sol" und "Jeff video" statt "Jev-Router" (so heißt das Video laut Beschreibung). Alle wörtlichen Zitate unten sind daher Rückübersetzungen aus dieser Spur. Zusätzlich habe ich alle 80 Frames gesehen: Sie zeigen Keynote-Ausschnitte mit eingeblendeter Quellenangabe ("OpenAI DevDay 2026, Keynote, 29.09.2026" mit Keynote-Zeitmarke) und deutschen Untertiteln, dazu den Sprecher im Studio. Die Videobeschreibung enthält Kapitelmarken, Preise und Quellenlinks; Angaben, die nur dort stehen, sind als "laut Beschreibung" gekennzeichnet. Die Zeitangaben (mm:ss) beziehen sich auf das Video, nicht auf die Keynote. Diese Datei führt zwei Fassungen zusammen: Grundlage ist die Fassung vom 10.10. (Frames gesichtet, 3 Prüfdurchläufe); aus der Fassung vom 04.10. (nur Auto-Captions und Beschreibung, der Videodownload war dort mit HTTP 403 gescheitert, keine Frames) stammen zusätzliche Einordnungs-Punkte im Abschnitt für das Team, ein Glossar-Eintrag, einzelne Modell- und Preisdetails aus The Next Web und The Decoder sowie weitere Querverweise; sie sind jeweils mit "aus Fassung vom 04.10." gekennzeichnet.
~~*Hinweis zum Ablauf: Transkript aus den englischen YouTube-Auto-Captions (yt-dlp, komplettes Video abgedeckt, kein Whisper nötig; die Captions sind teils fehlerhaft, z. B. "GPT 6.1 Soll" = Sol, "Jeff video" = vermutlich "Jev-Router" laut Videobeschreibung). Der Videodownload scheiterte mehrfach mit HTTP 403, daher wurden keine Frames gesichtet; die Zusammenfassung beruht auf Captions, Kapitelliste und der ausführlichen Videobeschreibung (Metadaten aus video.info.json). Der Videotitel ist auf YouTube deutsch, die Captions sind englisch; das language-Feld der Metadaten steht auf de-DE, die Captions heißen "en-orig"; die Tonsprache ist nur über Metadaten belegt, nicht durch Anhören. Wichtig: Eine Redaktionszeile in der Beschreibung trägt den Stand 30.09.2026, ist also nach dem Upload ergänzt worden.*~~

Worum geht es?

Am 29. September 2026 hat OpenAI auf seiner Entwicklerkonferenz **DevDay** in San Francisco eine Vielzahl von Neuerungen vorgestellt (das Video nennt keine Zahl; laut Berichten waren es mehr als 20: Suchtreffer, und die in der Beschreibung verlinkte 9to5Mac-Meldung ist laut Seitenüberschrift mit "20+ announcements" betitelt, nur ihr URL-Slug sagt "20-announcements"). Das Video pickt sieben davon heraus und erklärt sie in gut sechs Minuten. Die erste und laut Sprecher "die Innovation, auf die ich seit Jahren warte" ist **"Dots"**: ein KI-Helfer, der nicht mehr in einem Chatfenster wartet, bis man ihn anspricht, sondern dauerhaft im Hintergrund läuft, einen eigenen Cloud-Rechner hat und Aufgaben selbstständig abarbeitet. Bisher war ein KI-Assistent im Kern ein Gesprächspartner, der nur reagiert; mit Dots verschiebt sich das zu einem "Kollegen", dem man Zuständigkeiten gibt.
~~Am 29.09.2026 hat OpenAI auf seiner Entwicklerkonferenz **DevDay 2026** in San Francisco eine ganze Reihe von Neuerungen vorgestellt. Das Video fasst in gut fünf Minuten **sieben davon** zusammen. Die wichtigste Neuheit sind die **"Dots"**: KI-Helfer, die nicht mehr nur in einem Chatfenster sitzen, sondern dauerhaft im Hintergrund auf einem eigenen Cloud-Rechner arbeiten. Dazu kommen ein neues, deutlich billigeres Modell namens **GPT-6.1 Sol**, eine besonders schnelle Stufe ("Ultrafast") mit einem neuen 500-Dollar-Abo, eine **Decisions API** (eine KI, die nur auswählt statt Text zu schreiben), Codex in der Cloud, ein "Mit ChatGPT anmelden"-Knopf für fremde Apps und der Zwischenstand von OpenAIs Ziel eines "KI-Forschungspraktikanten".~~

Die übrigen sechs Neuheiten drehen sich um drei Fragen, die für Praktiker zählen: Was kostet das (ein neues, deutlich billigeres Modell, ein Bezahl-Turbo und neue Abo-Stufen)? Wie schnell ist es (Tempo-Stufe, ein Spezialmodell, das nur entscheidet)? Und wo läuft es (Programmieren in der Cloud, Abo in fremden Apps)? Den Abschluss bildet eine Einordnung des Sprechers, warum das alles gerade so schnell gehe: Er deutet OpenAIs Zahlen zum "KI-Forschungspraktikanten" so, dass KI inzwischen helfe, die nächste KI zu bauen. Das ist seine Schlussfolgerung, nicht ein Satz der Keynote-Folien; OpenAI selbst spricht dort von Forschungsbeschleunigung. Wichtig vorab: Das Video ist ein **begeisterter Nachrichtenzusammenschnitt**. Formulierungen wie "geheime Sensation" oder "hat mich umgehauen" sind die Wertung des Sprechers, die Fakten stammen aus der OpenAI-Keynote und sind teils vom Kanal in der Beschreibung ergänzt.
~~Vorher war ChatGPT im Kern ein Gesprächspartner: Man stellt eine Frage, bekommt eine Antwort, und nur solange das Fenster offen ist, passiert etwas. Das Video beschreibt den Schritt zu einer Arbeitsweise, in der man einer KI eine Dauerverantwortung überträgt, ähnlich wie einem Kollegen. Das ist wichtig, weil sich dadurch ändert, wofür man KI einsetzen kann (Überwachen, Abarbeiten, Nacharbeiten statt nur Beantworten) und auch, wie man dafür bezahlt. Gleichzeitig ist das Video eine wohlwollende Nachrichtenzusammenfassung eines Kanals, der den Ankündigungen sichtlich positiv gegenübersteht; die Angaben stammen größtenteils aus OpenAIs eigener Darstellung.~~

Neuheit 1: Dots, der rund um die Uhr arbeitende Helfer (0:33-1:30)

~~Was das Video sagt, Punkt für Punkt~~

Der Sprecher nennt Dots "die Innovation, auf die ich seit Jahren warte" (0:37). Ein Dot sei "kein Chatfenster mehr, sondern ein Helfer, der dauerhaft im Hintergrund läuft und ganz allein arbeitet"

(0:39). Man gibt ihm eine Verantwortung wie einem Kollegen, etwa "behalte meine Kundenanfragen im Blick", und er "fängt an und hört einfach nicht mehr auf" (0:46-0:52).
~~Die Zählung (1 bis 7) stammt vom Video selbst. Was nur in der Videobeschreibung steht und nicht im gesprochenen Text, ist gekennzeichnet.~~

Was dahintersteckt, laut Video und Beschreibung:

~~Einleitung (0:00-0:33)~~

- **Eigener Rechner in der Cloud:** Ein Dot hat laut Video einen eigenen Computer samt Browser, klickt sich durch Webseiten und schreibt Programme, "während dein Laptop längst zugeklappt ist" (0:58). Cloud heißt hier: Der Rechner steht bei OpenAI, nicht bei dir.
- **Anbindung an andere Programme:** Laut Beschreibung kann sich ein Dot mit über 4.000 Apps verbinden.
- **Er meldet sich selbst:** Der Sprecher sagt, man könne ihm "bald" per SMS schreiben oder ihn anrufen, und er melde sich seinerseits, sobald etwas eine Entscheidung braucht (1:05). Laut Beschreibung sind SMS und Anrufe angekündigt, aber noch nicht verfügbar.
- **Praxisbeispiel von OpenAI:** Entwickler bei OpenAI leiten Fehlermeldungen einfach an ihren Dot weiter und beheben so "Dutzende Bugs pro Tag" (1:14). Das ist eine Eigenaussage von OpenAI, die im Video nicht belegt wird.
- **Preis:** Der Dot sei im Abo enthalten, und Gespräche mit ihm zählten nicht gegen das Nutzungskontingent (1:25). Einordnung mit Beleg-Stufe: The Next Web (https://thenextweb.com/news/openai-dots-always-on-ai-agents-cloud-computers-devday; **Tool-Zusammenfassung**, im unabhängigen Prüfdurchlauf abgerufen, nicht von mir) nennt es differenzierter: "first dot is included", und Aufgaben, die der Dot in Codex oder ChatGPT Work startet, zählen dagegen mit. Für die Kostenplanung ist "im Abo enthalten" also nicht gleichbedeutend mit "kostenlos in der Nutzung".
  ~~Das Video verspricht die wichtigsten Fakten in fünf Minuten und kündigt an, dass Punkt 7 erkläre, warum alles gerade so schnell gehe.~~

Zur Verfügbarkeit sagt die Keynote-Einblendung (17:25): "Dots und Space gibt es ab heute für alle Nutzer von ChatGPT Pro, Business Premium und Enterprise". Das Video selbst sagt nur "jeder Pro-Kunde" (0:00). Die Beschreibung schränkt ein, und das ist für Europa wichtig: **Pro-Kunden in der EU, der Schweiz und Großbritannien bekommen die Dots laut OpenAI vorerst nicht, ein Termin steht nicht fest.** Mit dem Tarif Business Premium seien sie auch hier verfügbar, schrittweise freigeschaltet (Stand 30.09.2026).

~~1. Dots: Helfer, der rund um die Uhr arbeitet (0:33-1:31)~~

Meine Einordnung: Ein "Agent" ist ein Programm, das selbstständig Werkzeuge bedient, um ein Ziel zu erreichen (der Begriff ist nicht neu und wird im Video nicht erklärt). Dots sind OpenAIs Versuch, daraus ein Alltagsprodukt für Nicht-Entwickler zu machen. Wie zuverlässig das ist, zeigt das Video nicht; es zeigt nur Marketingfragmente. Ein anderes Video im Projekt (video-summary-a_jihWpd8cc.md) berichtet von Pannen bei den Live-Demos, die hier nicht vorkommen.

Laut Video ist ein Dot "kein Chatfenster mehr, sondern ein Helfer, der dauerhaft im Hintergrund läuft und ganz von allein arbeitet". Man gibt ihm eine Zuständigkeit wie einem Kollegen, zum Beispiel "Behalte meine Kundenanfragen im Auge", und er legt los und hört nicht mehr auf. Er hat einen **eigenen Computer mit Browser** (in der Cloud, also auf OpenAIs Servern), klickt sich durch Webseiten und schreibt sogar Programme, während der eigene Laptop längst zugeklappt ist. Die Videobeschreibung ergänzt: Er kann sich mit **über 4.000 Apps** verbinden.

Neuheit 2: GPT-6.1 Sol, "fast Spitzenklasse für ein Fünftel des Preises" (1:31-2:10)

Bald soll man ihm auch per SMS schreiben oder ihn anrufen können; er meldet sich dann ebenso bei einem, sobald etwas eine Entscheidung braucht. Laut Beschreibung sind SMS und Anrufe **angekündigt, aber noch nicht da**. Als Praxisbeispiel nennt das Video, dass OpenAI-Entwickler eine Fehlermeldung einfach an ihren Dot weiterleiten und so "dutzende Fehler pro Tag" beheben. Das ist eine Aussage über OpenAIs interne Nutzung; unabhängig geprüft ist sie nicht.

Der Sprecher sagt, dies sei die Antwort auf den Wunsch, den OpenAI am häufigsten höre: "Mach es endlich billiger" (1:36). **GPT-6.1 Sol** sei "fast so klug wie Astra, das Spitzenmodell von vor ein paar Wochen, kostet aber nur ein Fünftel" (1:46-1:51). Astra (GPT-6 Astra) ist das große Modell, das OpenAI Anfang September 2026 veröffentlicht hat (siehe gpt-6-astra-ueberblick.md).
Preis und Verfügbarkeit: Der Dot ist laut Video "bereits im Abo enthalten", und Gespräche mit ihm verbrauchen **nicht das eigene Nutzungskontingent**. Die Beschreibung präzisiert, mit Verweis auf OpenAIs Hilfeseite: verfügbar ab 29.09. für **Pro** (außer EU, Schweiz und UK), **Business Premium** und **Enterprise**. Eine Zeile (Stand 30.09.2026) sagt für Deutschland: Pro-Kunden in der EU, der Schweiz und UK bekommen Dots "vorerst noch nicht, einen Termin gibt es nicht"; mit Business Premium sind sie auch hier schon verfügbar, die Freischaltung läuft schrittweise.

Die Zahlen laut Beschreibung und Keynote-Folie (20:11): 2 Dollar je Million Eingabe-Token und 10 Dollar je Million Ausgabe-Token; Astra kostet zum Vergleich 10 und 50 Dollar, also tatsächlich das Fünffache. **Ein Token** ist die Recheneinheit, in der Sprachmodelle Text zählen, grob ein Wortstück; abgerechnet wird nach Tokens, getrennt für das, was man hineingibt (Eingabe), und das, was das Modell schreibt (Ausgabe).

2. GPT-6.1 Sol: fast Spitzenklasse für ein Fünftel des Preises (1:31-2:10)

Dazu kommt ein Preisnachlass, den der Sprecher mit einem Bild erklärt (1:52): Gibt man dem Modell denselben langen Text immer wieder, etwa ein Handbuch, zahlt man dafür 95 Prozent weniger. "Als würde man ein Buch nur beim ersten Mal zum vollen Preis bezahlen und danach fast nichts mehr." Laut Beschreibung kostet solcher wiederverwendeter Text ("Cached Input") 0,10 Dollar je Million Token. Das Prinzip heißt Prompt Caching: Der Anbieter merkt sich bereits verarbeiteten Text und berechnet ihn bei Wiederholung günstiger.
GPT-6.1 Sol ist ein neues Modell. Das Video nennt es die Antwort auf den Wunsch, den OpenAI am häufigsten höre: "Macht es endlich billiger." Sol sei "fast so schlau wie Astra", das Spitzenmodell von vor wenigen Wochen (GPT-6 Astra), koste aber nur ein Fünftel. Laut Beschreibung: **2 Dollar pro Million Eingabe-Token und 10 Dollar pro Million Ausgabe-Token** (Token sind die Textstückchen, nach denen KI-Anbieter abrechnen; ein Token entspricht grob einem Wortteil). Zum Vergleich: Astra

~~kostet laut unseren bestehenden Notizen 10 Dollar bzw. 50 Dollar, also genau das Fünffache; die Rechnung stimmt.~~

Die Folie bei 20:02 zeigt zudem ein Diagramm "DeepSWE" (eine Aufgabensammlung für Software-Entwicklung, dargestellt als Punktzahl gegenüber Kosten pro Aufgabe) mit der Einblendung "fast Astra-Intelligenz zu einem Fünftel des Preises". Die Kurve selbst ist im Video nicht erklärt; was gemessen wurde, steht nur auf der Folie. Das ist **OpenAIs eigene Messung**, keine unabhängige.
~~Dazu kommt ein Rabatt für **wiederverwendeten Text** ("Cached Input"): Gibt man dem Modell immer wieder denselben langen Text, etwa ein Handbuch, zahlt man dafür laut Beschreibung 0,10 Dollar statt 2 Dollar, also **95 Prozent weniger**. Das Video vergleicht das mit einem Buch, das man nur beim ersten Lesen voll bezahlt.~~

Neuheit 3: Ultrafast und das neue Abo Pro 500 (2:10-2:50)

~~**3. Ultrafast und das neue ChatGPT Pro 500 (2:10-2:50)**~~

Hier geht es um Geschwindigkeit. Zur Veranschaulichung ließ OpenAI zwei 3D-Simulationen mit Roboterarmen nebeneinander denselben Auftrag ausführen ("Erstelle und starte eine weiße Rakete mit einem großen Bullauge in den DevDay-Farben"): Links ("Ultrafast") fliegt die Rakete schon, während rechts ("Regular") noch gebaut wird (2:13-2:30, Frames bei Keynote-Zeit 21:04-21:16).
~~Als Showeffekt ließ OpenAI laut Video zwei Raketen nebeneinander bauen: Die linke startet schon, während die rechte noch im Bau ist. Gemeint ist die Geschwindigkeit: bis zu **300 Token pro Sekunde**, das Video sagt "fast eine ganze Buchseite pro Sekunde". Dafür gibt es ein neues Abo, **Pro 500**, mit laut Video **25-mal so viel Nutzung wie Plus** und dem Turbo in ChatGPT und Codex. Die Beschreibung ergänzt: Ultrafast sei **bis zu 8-mal schneller in Codex** und **bis zu 6-mal schneller in der API, zum 6-fachen Preis**; Pro 500 koste laut The Decoder 500 Dollar im Monat. Wer so viel nicht braucht, bekommt das **Pro-Abo** zurück (laut Beschreibung 200 Dollar), "mit einem Arbeitstier, das man den ganzen Tag laufen lassen kann".~~

- **Ultrafast** ist eine zusätzliche, bezahlte Tempo-Stufe. Auf der Folie steht: "Verfügbar in API, ChatGPT und Codex; 8x schneller, bis zu 300 Tokens pro Sekunde". Der Sprecher übersetzt das: Das sei "fast eine ganze Buchseite pro Sekunde" (2:31).
- Laut Beschreibung gilt "bis zu achtmal schneller" in Codex und "bis zu sechsmal" in der API, und zwar **zum sechsfachen Preis**. Der sechsfache Preis steht auch in einer Keynote-Einblendung bei Keynote 20:55 (Videozeit ca. 2:21): "Ultra Fast bringt es auf achtfaches Tempo zum sechsfachen Preis."; ebenso bei The Decoder (Tool-Zusammenfassung).
- **Pro 500** ist ein neues Abo mit "25-mal so viel Nutzung wie Plus", enthält Ultrafast in ChatGPT und Codex (2:36). Die Folie (Keynote 21:45, im hochaufgelösten Frame bei Videozeit 2:39 gelesen) listet "Ultrafast, No 5hr limit, Use across partner apps, 25x usage of Plus". "No 5hr limit" heißt offenbar: kein Nutzungslimit pro Fünf-Stunden-Fenster. Das Video erklärt das nicht; die genaue Bedeutung habe ich nicht geprüft. "Use across partner apps" bezieht sich vermutlich auf die Nutzung des Abos in Partner-Apps (vgl. "Sign in with ChatGPT" unten); das ist meine Lesart.

- "Wenn du nicht so viel brauchst, bekommst du auch das Pro zurück", sagt der Sprecher (2:43), und dazu ein "Arbeitspferd, das du den ganzen Tag laufen lassen kannst". Gemeint ist laut Beschreibung das Pro-200-Abo, das "zurückkommt". Auf der Folie steht bei Keynote 21:45 "Pro 500" allein; bei 21:53 sind links zusätzlich 100 und 200 zu sehen, passend zu mehreren Pro-Stufen.
  ~~Wichtig für die Einordnung: Das Video sagt im gesprochenen Text nur "bis zu 300 Token pro Sekunde", "Turbo" und Pro 500 mit 25-mal Plus. Die Videobeschreibung (nicht der Ton) nennt nicht pauschal "8-fache Geschwindigkeit zum 6-fachen Preis" (so stand es verkürzt in einem früheren Video), sondern unterscheidet Codex (bis 8x) und API (bis 6x). Die Preise schwanken außerdem je nach Modell: Auf Astra bezogen nennt The Decoder 60 Dollar bzw. 300 Dollar pro Million Token.~~

Meine Einordnung: Ultrafast ist eine Preisstaffelung nach Wartezeit, wie ein Expressversand. Sinnvoll ist das dort, wo ein Mensch auf die Antwort wartet; bei Aufgaben, die über Nacht laufen können, ist das Geld nicht gut angelegt. Der sechsfache Preis steht in der Keynote-Einblendung und in der Beschreibung; die Dollarwerte für Astra Ultrafast (60 Dollar Eingabe, 300 Dollar Ausgabe je Million Token, also sechsmal die Normalpreise 10/50) stammen aus The Decoder (Tool-Zusammenfassung).

~~**4. Decisions API: eine KI, die nur entscheidet (2:50-3:31)**~~

Neuheit 4: Die Decisions API, eine KI, die nur entscheidet (2:50-3:31)

~~Das Video nennt das seine "heimliche Sensation". Man gibt der KI eine **feste Liste an Antworten** und eine Frage (Text oder Bild), und sie wählt blitzschnell eine aus, zum Beispiel, welches Modell eine Anfrage bekommen soll. Laut Beschreibung (zitiert nach The Decoder) braucht eine Entscheidung **rund 150 Millisekunden statt 1,6 Sekunden** über die normale API. Das ist das Prinzip eines "Routers", den der Kanal in einem früheren Video behandelt hat. Weil das Modell auch Bilder versteht, könnten Roboter es nutzen, um fast in Echtzeit auf das zu reagieren, was sie sehen. In der Demo klickt sich die KI durch einen ganzen Computer; OpenAI betone laut Video, dass dabei nichts beschleunigt wurde. Die Decisions API startet als **begrenzte Vorschau**.~~

Der Sprecher nennt dies seine "geheime Sensation" (2:54; der Satz beginnt bei 2:53). Normalerweise erzeugt ein KI-Modell Text, Wort für Wort. Die **Decisions API** tut das nicht: Man gibt ihr eine Frage mit einer **festen Liste möglicher Antworten**, dazu Text oder ein Bild, und sie wählt eine davon, "blitzschnell" (3:07). Als Beispiel nennt er, welches Modell eine Anfrage bekommen soll. In der Keynote sagt der Redner laut deutschem Untertitel (Keynote 22:40): "Das funktioniert, indem unser Modell Luna eine feste Auswahl an Optionen bekommt" und nennt als Einsatzbeispiele "eine Anfrage weiterleiten, ein Bild einordnen oder entscheiden, was ein Agent als Nächstes tut". Das ist gesprochener Text, kein Folientext. Die Bühnenfolie heißt "Decisions API" mit dem Zusatz "In preview"; "Near-Realtime Decisions" ist die Überschrift des gezeigten Demo-Bildschirms.
~~Eigene Erklärung: Der Nutzen liegt nicht im "klügeren" Modell, sondern im günstigen, schnellen Sortieren. Wer viele Anfragen hat, kann eine kleine, schnelle Instanz entscheiden lassen, wohin sie gehen, und das teure Modell nur für schwere Fälle einsetzen. Laut The Decoder (Tool-Zusammenfassung) nutzt die Decisions API "a version of GPT-6 Luna, its low-cost model" (ein~~

günstiges OpenAI-Modell, laut TNW am 22.09.2026 zusammen mit GPT-6 Sol erschienen), und die 150 ms werden mit "GPT-6 Luna through the regular API" (1,6 s) verglichen; das Video selbst nennt Luna nicht (siehe "Zu prüfen").

Zeitangabe laut Beschreibung (die sich auf The Decoder beruft): Eine Entscheidung dauert rund 150 Millisekunden statt 1,6 Sekunden bei der regulären GPT-6-Luna-API (laut The Decoder, Tool-Zusammenfassung; dort nutzt die Decisions API "a version of GPT-6 Luna"). Das wäre etwa zehnmal so schnell. Die Decisions API startet als "begrenzte Vorschau" (Limited Preview). Zur Demo sagt der Sprecher, die KI "klickt sich durch einen ganzen Computer", und OpenAI betone ausdrücklich, dass nichts beschleunigt wurde (3:19). Dass Roboter damit "bald in Beinahe-Echtzeit auf das reagieren könnten, was sie sehen" (3:27), ist die Folgerung des Sprechers, keine Ankündigung von OpenAI.

5. Codex läuft komplett in der Cloud (3:31-4:15)

Warum das nützlich ist, erkläre ich so: Viele Abläufe brauchen gar keinen Text, sondern eine **Weiche**: Ist diese Anfrage einfach oder schwer? Gehört dieses Bild zu Kategorie A oder B? Für so etwas braucht man keine seitenlange Antwort, sondern eine schnelle, billige Auswahl aus einer Liste. Der Sprecher sagt, wer sein früheres Video zu diesem Thema kenne, erkenne das Prinzip sofort (3:14); laut Beschreibung ist das sein "Jev-Router"-Video (Router = Verteiler, der Anfragen an das passende Modell weiterreicht).
Codex ist OpenAIs Programmier-Assistent. Neu: Er läuft vollständig in der Cloud. Man startet eine Aufgabe auf dem Handy, prüft sie im Browser und macht am Schreibtisch weiter, während der Agent einfach weiterarbeitet. Auf der Bühne ließ Romain (im Transkript nur der Vorname; dass es Romain Huet von OpenAI ist, ist meine Ergänzung aus den früheren Notizen, nicht im Video belegt) laut Video das komplette Backend einer App in **Rust** umschreiben (Rust ist eine Programmiersprache; es ist, als würde man den Maschinenraum der App in einer anderen Sprache neu bauen). Das dauert Stunden, ist aber egal: Er schickt es in die Cloud, klappt den Laptop zu und schaut später nach. Außerdem hat OpenAI laut Video **die Maschine, die Codex ausführt, als Open Source veröffentlicht**, sodass jeder hineinsehen und darauf aufbauen kann.

Neuheit 5: Codex läuft jetzt in der Cloud (3:31-4:15)

---

6. "Mit ChatGPT anmelden" und Apps in ChatGPT (4:15-4:50)

Codex ist OpenAIs Programmier-Assistent. Neu ist laut Video, dass er "komplett in der Cloud" läuft: Man startet eine Aufgabe am Handy, prüft sie im Browser und macht am Schreibtisch weiter, "während der Agent einfach weiterarbeitet" (3:40-3:51). Eingeblendet wird "Deine Agenten arbeiten weiter, wo immer du bist" und "Du musst dir keine Sorgen machen, den Laptop mitten im Lauf zuzuklappen".
Mit **Sign in with ChatGPT** meldet man sich bei Fremd-Apps mit dem ChatGPT-Konto an, und die App nutzt dann das eigene Abo, statt ein zweites KI-Abo verkaufen zu wollen. Das könnte nach Einschätzung des Videos ändern, wie man künftig für KI bezahlt. Außerdem laufen ganze Programme direkt in ChatGPT, etwa Figma oder Adobe Photoshop, neben der Unterhaltung. Mit **1,2 Milliarden Nutzern pro Woche** (Angabe im Video, nicht geprüft) werde ChatGPT so zu einem eigenen App-Store.

Als Demo habe "Romain" (laut anderem Projektmaterial Romain Huet von OpenAI) auf der Bühne den Auftrag getippt, das **gesamte Backend in Rust neu zu schreiben**, also den "Maschinenraum" einer App in einer anderen Programmiersprache (3:51). Das dauere Stunden, was nicht stört, weil er es in die Cloud schickt, den Laptop zuklappt und später nachschaut (4:01). Was dabei herauskam, zeigt das Video nicht.

~~7. Der "KI-Forschungspraktikant" (4:50-5:34)~~

Außerdem habe OpenAI "die Maschine, die Codex antreibt", als Open Source veröffentlicht, damit jeder hineinschauen und darauf aufbauen kann (4:08); im Bild steht "Codex Harness" (Keynote 27:51). Ein **Harness** ist die Software drumherum, die einem Sprachmodell erlaubt, Werkzeuge zu bedienen, Befehle auszuführen und eine Aufgabe über viele Schritte im Blick zu behalten. Beachte: Offen ist damit das Gerüst, nicht das Modell dahinter.
~~OpenAI hatte vor einem Jahr versprochen, einen **KI-Forschungspraktikanten** zu liefern (im Video: "exactly one year ago"; ein Zieldatum nennt das Video nicht), was laut Video kaum jemand glaubte. Der Zwischenstand laut Video: Im Januar scheiterten die Modelle fast immer an Forschungsaufgaben, für die ein Mensch einen ganzen Tag braucht. **Seit Juli erledigen sie über ein Drittel dieser Tagesaufgaben allein** und haben geholfen, **über 100 jahrzehntelang offene Mathematikprobleme** zu lösen. Folgerung des Videos: KI hilft inzwischen, die nächste KI zu bauen, und deshalb explodiere das Tempo der Neuerungen. Das ist eine Deutung des Kanals; die Zahlen stammen aus OpenAIs Darstellung und wurden nicht unabhängig geprüft. "Offene Probleme gelöst" kann zudem sehr Unterschiedliches bedeuten (Teilbeweise, Hilfe bei Einzelschritten), das erklärt das Video nicht.~~

Neuheit 6: "Sign in with ChatGPT" und Programme in ChatGPT (4:15-4:50)

~~Schluss: Sam Altman (5:34-6:05)~~

Bisher zahlt man, wenn man eine fremde App mit KI nutzen will, oft zusätzlich ein eigenes KI-Abo dieser App. Mit **"Sign in with ChatGPT"** meldet man sich in der fremden App mit seinem ChatGPT-Konto an, und die App verbraucht dann das **vorhandene ChatGPT-Abo** (4:21-4:33). Die Keynote-Einblendung dazu (44:45): "...die in ihrem ChatGPT-Abo stecken", im Demo-Bild laufen Beispiele "Grow your business" und "Build your product" mit einem Anmeldefenster.
~~Am Ende habe Sam Altman etwas gesagt, womit niemand gerechnet habe: Er wolle nicht, dass KI die Menschen zu Zahnrädern in einer immer schnelleren Maschine macht, sondern dass sie **mehr Kontrolle über das eigene Leben** gibt. Das ist eine Absichtserklärung; sie beschreibt kein Produkt.~~

Daneben liefen jetzt "ganze Programme" direkt in ChatGPT, genannt werden Figma und Adobe Photoshop, neben dem Gespräch (4:36). Mit 1,2 Milliarden wöchentlichen Nutzern werde ChatGPT "zu einem riesigen App-Store" (4:41). Die Zahl 1,2 Mrd. steht auch auf einer Keynote-Folie ("1.2B people use ChatGPT every week", 44:12).

~~Einordnung und Plausibilität~~

Meine Einordnung: Das Wichtigste ist die Bezahllogik. Das Abo bei OpenAI wird zu einer Art Universal-Guthaben, das in anderer Software eingelöst werden kann. Für Firmen bedeutet das aber auch, dass Nutzungsdaten und Verbrauch über das eigene ChatGPT-Konto laufen; wie das organisatorisch abgesichert ist, sagt das Video nicht.

- **Namensfrage "GPT-6.1 Sol" gegenüber "GPT-5.6 Sol":** Das Video nennt durchgängig **GPT-6.1 Sol** (die Beschreibung ebenso). The Next Web schreibt laut Abruf (Tool-Zusammenfassung) sinngemäß, das Modell sei "an upgrade to GPT-6 Sol, which OpenAI released on 22 September alongside a cheaper Luna model". GPT-6.1 Sol ist demnach das Upgrade von **GPT-6 Sol** (22.09.2026, zusammen mit dem günstigen Modell Luna), und GPT-6 Sol ist der unmittelbare Vorgänger. Das passt zu den "GPT-6 Sol/Luna"-Videos in den Notizen. Wie sich "GPT-5.6 Sol" (so in gpt-6-astra-ueberblick.md) zu "GPT-6 Sol" verhält, bleibt ungeklärt; TNW erwähnt "GPT-5.6 Sol" nicht.
- **Preise Sol:** 2 Dollar/10 Dollar/0,10 Dollar cached (Video-Beschreibung) stimmen mit The Next Web überein (Tool-Zusammenfassung). TNW nennt zusätzlich laut Abruf (sinngemäß, Tool-Zusammenfassung): Sol erreicht fast Astra-Niveau bei einem Fünftel der Astra-Preise; auf DeepSWE v1.1 gleichauf mit Astra bei etwa einem Fünftel der Kosten, auf OSWorld 2.0 (Computer-Bedienung) 2,1 Punkte hinter Astra bei etwa einem Siebtel der Kosten pro Aufgabe. "Fast so schlau wie Astra" ist also durch zwei genannte Benchmarks gedeckt, aber das sind Herstellerangaben.
- **Dots-Preise 100/200/500 Dollar:** Das Video behandelt **keine Dot-Einzelpreise**. Es sagt nur: im Abo enthalten (Pro ohne EU/CH/UK, Business Premium, Enterprise). Neu und belegt: **Pro 500 = 500 Dollar im Monat** (The Decoder laut Abruf: Tool-Zusammenfassung) und die Kürzung des **Pro-200-Plans** (GPT-6-Pro-Nachrichten von 200 auf 100 pro Woche; laut The Decoder, Tool-Zusammenfassung, wird die Nutzung zusätzlich von 20-fach auf 10-fach Plus gesenkt). Damit sind die "100/200/500-Stufen" in den Quellen zumindest teils erklärbar: 200 und 500 sind Pro-Tarife; woher die "100 Dollar"-Zahl stammt, klärt dieses Video nicht.
- **Ultrafast:** Die Videobeschreibung nennt "bis 8x" (Codex) und "bis 6x" (API) bei 6-fachem Preis (im gesprochenen Text nicht); The Decoder nennt laut Abruf (Tool-Zusammenfassung) 6x Preis und 60/300 Dollar für Astra. Die frühere Kurzformel "8x schneller für 6x Preis" gilt demnach nur für Codex, in der API sind es bis zu 6x.
- **Decisions API:** 150 Millisekunden gegenüber 1,6 Sekunden bestätigt The Decoder laut Abruf (Tool-Zusammenfassung).
- **Tonfall:** Der Kanal wertet ohne Gegenstimme ("blew me away", "secret sensation"). Die Live-Panne der Dots-Demo, über die das Satire-Video und andere Quellen berichten, kommt im Transkript nicht vor (Frames nicht gesichtet). Das Bild ist daher einseitig positiv.
- **Quellenlage:** Die Beschreibung nennt als Quellen OpenAI-Hilfeseite, OpenAI-Keynote, The Decoder, The Next Web und 9to5Mac. Die OpenAI-Hilfeseite war für mich **nicht abrufbar** (403).

Neuheit 7: Der KI-Forschungspraktikant (4:50-5:34)

Nutzen für dich (Allround, Code, lokale KI)

Der Sprecher kündigt dies mit "hat mich umgehauen" an (4:49; schon zu Beginn sagt er, Nummer 7 habe ihn umgehauen, 0:32) und fragt am Ende die Zuschauer, welche der sieben Neuheiten sie am

meisten umhaue (6:00). Die Keynote-Folien zeigen ein Zitat vom 28.10.2025 (englisch: "We are making plans around getting to quite capable AI research interns that can meaningfully accelerate our researchers"; sinngemäß: Man mache Pläne, um zu ziemlich fähigen KI-Forschungspraktikanten zu gelangen, die die Forscher spürbar beschleunigen können) und einen OpenAI-Blogartikel "Research acceleration: The view inside OpenAI" mit dem Satz: **"We have now reached the goal of having an automated research intern by September of this year"** (Keynote 23:53). Das Versprechen war also, laut Folie, im Oktober 2025 gegeben worden; der Sprecher sagt "genau vor einem Jahr" (4:54), tatsächlich sind es auf der Folie rund elf Monate.

Die Zahlen, die der Sprecher dazu nennt (5:10-5:27):

- Im Januar scheiterten die Modelle "fast immer" an Forschungsaufgaben, für die ein Mensch einen ganzen Tag braucht.
- Seit Juli erledigen sie **über ein Drittel** dieser Tagesaufgaben allein. Auf der Folie (Keynote 26:29-26:39) steht ein Diagramm "Agents are increasingly solving more complex problems for researchers" mit zwei Serien (Januar 2026 grau, Juli 2026 blau). Die senkrechte Achse heißt "Agentic usage / researcher / day" (im Video nicht erklärt), die waagerechte "Estimated time for a human". Eine Einblendung daneben nennt als "Success rate" für 8-16-Stunden-Aufgaben "with 0 interventions" 35 % (Juli 2026) gegenüber 10 % (Januar 2026). Das "über ein Drittel" steht im deutschen Untertitel der Einblendung (26:39): "Unsere Modelle haben über ein Drittel der ganztägigen Forschungsaufgaben übernommen". Gemeint sind also Aufgaben von 8-16 Stunden menschlicher Arbeitszeit, die ohne jeden menschlichen Eingriff erledigt wurden (nach OpenAIs eigener Auswertung).
- Die KI habe geholfen, **über 100 seit Jahrzehnten offene Mathematikprobleme** zu lösen (5:24).

Der Sprecher folgert daraus: "KI hilft jetzt, die nächste KI zu bauen, und genau deshalb explodieren die Neuerungen gerade in diesem irren Tempo" (5:27). Das ist eine plausible, aber **vom Sprecher gezogene** Schlussfolgerung; die Folie belegt nur den Anteil erledigter Aufgaben in OpenAIs eigenen Auswertungen. Einordnung in "Zu prüfen".

Schluss: Sam Altman, "keine Maschine aus Menschen" (5:34-6:05)

Zum Schluss habe Altman "etwas gesagt, das keiner erwartet hat" (5:36): Er wolle nicht, dass KI die Menschen zu "Zahnrädern in einer immer schnelleren Maschine" mache, sondern etwas, das mehr Kontrolle über das eigene Leben gibt (5:45-5:52). Die Keynote-Einblendungen bestätigen den Tenor: "Oft wird KI eine neue industrielle Revolution genannt" (52:39), "Das finde ich ziemlich abstoßend" (52:39) und "Ich glaube, wenn wir es richtig machen, wird die Zukunft viel mehr eine neue Renaissance als eine neue industrielle Revolution" (52:55). Das Wort "Zahnräder" fällt in den gesehenen Einblendungen nicht; es ist die Zuspitzung des Sprechers. Der Bezug von "abstoßend" ergibt sich aus der Reihenfolge: Unmittelbar vorher steht "Oft wird KI eine neue industrielle Revolution genannt", und bei 52:55 folgt "viel mehr eine neue Renaissance als eine neue industrielle Revolution". Altman findet also offenbar das Bild der KI als "industrielle Revolution" abstoßend; was genau er daran ablehnt, zeigen die Einzelausschnitte nicht. Wie "richtig machen" aussieht, sagen sie ebenfalls nicht. Es ist eine Absichtserklärung, keine Maßnahme.

Für Hardware-Entwickler und Team-Lead

(Eigene Einordnung, nicht aus dem Video, außer wo angegeben.)

- **Lizenzfrage für Europa zuerst klären:** Laut Beschreibung gibt es Dots für Pro in der EU, der Schweiz und Großbritannien vorerst nicht, mit Business Premium aber schon. Für eine Team-Evaluation bedeutet das: Ein privates Pro-Konto reicht in Europa derzeit nicht. Die Pro-Stufe ist keine Option, die sich einfach "ausprobieren" lässt.
- **Ein Agent mit eigenem Rechner und 4.000 Anbindungen ist eine Zugriffs- und Datenschutzfrage:** Ein Dot arbeitet weiter, wenn niemand hinsieht. Das Video nennt keine Kontrollmechanismen. Vor jedem Einsatz im Team gehört geklärt, auf welche Konten, Repositories und Dokumente er zugreifen darf und wer seine Aktionen prüft. (Eine Quelle nennt "Custom Rules" zum Erlauben, Blockieren oder Freigeben einzelner Aktionen; nur als Tool-Zusammenfassung abgerufen, siehe "Zu prüfen".)
- **Kosten: Prompt Caching ist für Hardware-Teams der interessanteste Punkt:** Wer dasselbe Datenblatt, dieselbe Norm oder dieselbe Spezifikation immer wieder als Kontext mitgibt, zahlt laut Video für den wiederholten Teil nur 5 Prozent. Das ist ein konkreter Hebel für Dokumenten-Fragen, Review-Assistenten und Änderungsprüfungen. Die tatsächlichen Einsparungen hängen davon ab, wie oft der Text unverändert wiederkehrt.
- **Tempo nur dort bezahlen, wo jemand wartet:** Ultrafast kostet sechsfach. Für interaktives Debuggen ein Argument, für Nachtläufe (Regressionstests, Dokumentenabgleich) nicht.
- **Decisions API als Weiche statt als Textgenerator:** Für Triage (Welcher Fehlerbericht geht an welches Team? Ist diese Anfrage Routine?) ist "feste Liste, eine Antwort, sehr schnell" oft robuster als ein frei formulierter Text, weil sich die Ausgabe automatisch weiterverarbeiten und prüfen lässt. Noch ist es eine begrenzte Vorschau; The Decoder (Tool-Zusammenfassung; aus Fassung vom 04.10.) nennt allerdings "broad availability expected in the coming days". Für die Planung also beobachten, aber noch nicht fest einplanen.
- **"Sign in with ChatGPT" als Governance-Thema:** Mitarbeiter könnten Firmenaufgaben über private Abos in Drittwerkzeugen laufen lassen. Eine Teamregel dazu (welches Konto, welche Daten) ist sinnvoller, als zu hoffen, dass es nicht passiert. Anknüpfungspunkt: ki-guidelines-hardware-unit.md.
- **Cloud-Agent oder selbst betriebener Agent?** (aus Fassung vom 04.10.) Dots und Cloud-Codex sind der Gegenentwurf zu Agenten auf dem eigenen Rechner: Vorteil ist, dass sie weiterlaufen, auch wenn der Laptop aus ist; Nachteil ist, dass Daten und Zugänge in der Cloud liegen. Wer das nicht will, bleibt bei lokaler KI (siehe lokale-ki.md).
- **Weiche lokal nachbauen** (aus Fassung vom 04.10.): Das Prinzip der Decisions API, "kleines schnelles Modell sortiert, großes arbeitet", lässt sich auch lokal umsetzen: Ein kleines lokales Modell entscheidet, welche Anfragen an ein großes (lokal oder Cloud) weitergehen. Das Video liefert die Idee, nicht die Umsetzung.
- **Sol für Alltagsaufgaben über die API** (aus Fassung vom 04.10.): Wenn Sol wirklich nahe an Astra liegt und nur ein Fünftel kostet, ist es der naheliegende Kandidat für Alltagsaufgaben; die Leistungsangaben sind aber Herstellerangaben (siehe "Zu prüfen").

- **Die Forschungspraktikanten-Zahlen nicht als Planungsgröße übernehmen:** Es sind OpenAIs eigene Auswertungen an OpenAI-Aufgaben. Eine weitere Quelle (Tool-Zusammenfassung) nennt, dass bei Aufgaben von 4 bis 8 Menschenstunden mehr als die Hälfte der erfolgreichen Läufe mindestens einen menschlichen Eingriff brauchte. Für ein Entwicklungsteam heißt das: Mehrstündige Teilaufgaben wirklich delegierbar zu machen braucht weiterhin Prüfschritte und Freigaben.
- **~~Preis-Leistung beim Coden und Chatten:~~** ~~Wenn Sol wirklich nahe an Astra liegt und nur ein Fünftel kostet, ist das der Kandidat für Alltagsaufgaben über die API. Der Cached-Input-Rabatt lohnt vor allem bei immer gleichen langen Vorgaben (Handbücher, Projektbeschreibungen).~~
- **~~Agenten:~~** ~~Dots und Cloud-Codex sind die Gegenentwürfe zu selbst betriebenen Agenten auf dem eigenen Rechner. Vorteil: läuft weiter, auch wenn der Laptop aus ist. Nachteil: Daten und Zugänge liegen in der Cloud; wer das nicht will, bleibt bei lokaler KI. Für Nutzer in der EU: Dots für Pro sind laut Beschreibung vorerst nicht verfügbar.~~
- **~~Routing-Idee (Decisions API):~~** ~~Das Prinzip "kleines schnelles Modell sortiert, großes arbeitet" lässt sich auch lokal nachbauen: ein kleines lokales Modell entscheidet, welche Anfragen an ein großes (lokal oder Cloud) weitergehen. Das Video liefert dafür die Idee, nicht die Umsetzung.~~
- **~~Hardware-Bezug:~~** ~~Keine Aussagen im Video.~~

Begriffe

- **Dot:** OpenAIs dauerhaft laufender Hintergrund-Agent in ChatGPT, mit eigenem Cloud-Rechner und Anbindung an viele Apps.
- **Agent:** Ein KI-Programm, das mit Werkzeugen (Browser, Programme, Konten) selbstständig Aufgaben ausführt, statt nur zu antworten.
- **Token:** Zähleinheit für Text bei Sprachmodellen (grob ein Wortstück); Preise und Tempo werden pro Token angegeben.
- **Cached Input (Prompt Caching):** Bereits verarbeiteter Eingabetext, den der Anbieter beim Wiederholen billiger berechnet, im Video 95 Prozent günstiger.
- **API:** Schnittstelle, über die Programme direkt auf ein KI-Modell zugreifen, im Gegensatz zur Chat-Oberfläche. Abgerechnet wird nach Tokens.
- **Ultrafast:** Bezahlte Tempo-Stufe: bis zu 8x schneller (Codex) bzw. 6x (API) zum 6-fachen Preis (laut Beschreibung; 8x Tempo zum 6-fachen Preis auch in einer Keynote-Einblendung).
- **Decisions API:** Spezialschnittstelle, die aus einer vorgegebenen Liste eine Antwort wählt, statt Text zu schreiben; derzeit begrenzte Vorschau.
- **Codex:** OpenAIs Programmier-Assistent, der laut Video jetzt komplett in der Cloud lauffähig ist (aus Fassung vom 04.10.).
- **Harness:** Die Software um ein Sprachmodell herum, die Werkzeugnutzung und mehrstufige Aufgaben steuert (hier: bei Codex als Open Source veröffentlicht).
- **~~Dot:~~** ~~OpenAIs neuer Dauer-Agent in ChatGPT: ein Helfer mit eigenem Cloud-Computer, der im Hintergrund weiterarbeitet, auch wenn man offline ist.~~

- **Agent (KI-Agent):** Programm, das selbstständig Aufgaben erledigt (Webseiten bedienen, Programme schreiben), statt nur Fragen zu beantworten.
- **Token:** Abrechnungseinheit der Anbieter; Textstückchen, grob ein Wortteil. Preise werden pro Million Token angegeben.
- **API:** Schnittstelle, über die Programme (statt Menschen im Chatfenster) ein Modell ansprechen und pro Nutzung bezahlen.
- **Cached Input:** Bereits verarbeiteter, wiederverwendeter Eingabetext, der deutlich billiger berechnet wird.
- **Ultrafast:** Schnelle, teurere Betriebsstufe eines Modells (bis zu 300 Token pro Sekunde); bis zu 8x in Codex und bis zu 6x in der API.
- **Decisions API:** Schnittstelle, in der das Modell nur aus einer vorgegebenen Antwortliste auswählt, dafür sehr schnell (laut Quelle ca. 150 ms).
- **Codex:** OpenAIs Programmier-Assistent, jetzt komplett in der Cloud lauffähig.

Kernbotschaft

OpenAI verschiebt ChatGPT auf dem DevDay 2026 vom Chatfenster zu einer Plattform, in der Agenten ("Dots") dauerhaft arbeiten, ein neues, fünfmal billigeres Modell (GPT-6.1 Sol) und eine bezahlte Tempo-Stufe die Kosten- und Wartezeit-Frage neu aufmachen und das Abo auch in fremden Apps nutzbar wird. Das Video liefert die Ankündigungen schnell und anschaulich, bleibt aber bei Marketing-Ausschnitten: Zuverlässigkeit, Sicherheit und Kontrollmöglichkeiten der Agenten kommen nicht vor, und für Europa gilt die Einschränkung, dass Dots mit dem Pro-Abo hier vorerst fehlen.
OpenAI hat auf dem DevDay 2026 KI vom Chatfenster zum Dauerhelfer gemacht (Dots, Cloud-Codex), das Spitzenmodell durch ein fast gleich gutes Modell für ein Fünftel des Preises ergänzt (GPT-6.1 Sol, 2/10 Dollar je Million Token) und am oberen Ende ein Tempo-Abo (Pro 500) eingeführt. Das Video ist eine wohlwollende Zusammenfassung, deren Kernzahlen (Preise, Ultrafast, Decisions API) laut Tool-Zusammenfassungen von TNW und The Decoder zu den Presseberichten passen, aber ohne Kritik und überwiegend mit OpenAIs Eigenangaben (inklusive des KI-Forschungspraktikanten). Für Nutzer zählen vor allem das neue Preis-Leistungs-Verhältnis von Sol und die Frage, ob man seine Aufgaben einem Cloud-Agenten anvertrauen will.

Themen-Tags

OpenAI, DevDay 2026, Dots, KI-Agenten, GPT-6.1 Sol, GPT-6 Astra, Ultrafast, Pro 500, Decisions API, Codex, Codex Cloud, Harness, Sign in with ChatGPT, Prompt Caching, KI-Forschungspraktikant, Sam Altman, EU-Verfügbarkeit, Preisgestaltung, KI-Agenten Governance
OpenAI, DevDay 2026, Dots, GPT-6.1 Sol, Ultrafast, Pro 500, Decisions API, Codex Cloud, Sign in with ChatGPT, KI-Forschungspraktikant, KI-Agenten, API-Preise

Zu prüfen

Es war kein Volltext einer Primär- oder Nachrichtenseite abrufbar; alle Webangaben unten sind Tool-Zusammenfassungen oder Suchtreffer. Als Quellen nennt die Videobeschreibung die OpenAI-Hilfeseite, die OpenAI-Keynote, The Decoder, The Next Web und 9to5Mac (aus Fassung vom 04.10.).

- **Dots, Regionen und Tarife:** Die Beschreibung des Kanals nennt den Ausschluss von Pro in EU/CH/UK und die Verfügbarkeit von Business Premium. Der in der Beschreibung verlinkte OpenAI-Hilfeartikel war **nicht abrufbar** (HTTP 403). Suchtreffer mehrerer Drittseiten (u. a. eesel.ai, nerdschalk.com, dotsguide.com; **Suchtreffer**) nennen dasselbe: Pro ohne EWR, Schweiz und Großbritannien, Business Premium überall, schrittweise Freischaltung. Das sind Dritt-Blogs, keine Primärquelle. Ein Live-Blog von Simon Willison (**Tool-Zusammenfassung**) hält fest, dass beim Erstellen eines Dots auf dem Handy "Please create a dot on your computer" erschien; ob das ein Dauerzustand ist, ist offen.
- **Preise Sol/Ultrafast:** The Next Web nennt 2 $/10 $ je Million Token, 0,10 $ Cached Input (95 % weniger) und "near-Astra intelligence for a fifth of the price" (DeepSWE v1.1: auf Astra-Niveau; OSWorld 2.0 2,1 Punkte unter Astra; Verfügbarkeit u. a. in ChatGPT Work und Codex; **Tool-Zusammenfassung**). The Decoder nennt Ultrafast mit bis zu 8x (Codex, 300 Tok/s), bis zu 6x (API), sechsfachem Preis und Astra Ultrafast 60 $/300 $ (**Tool-Zusammenfassung**). Das deckt sich mit der Videobeschreibung. Die Benchmark-Aussagen sind OpenAIs eigene Angaben. Aus der Fassung vom 04.10. (Tool-Zusammenfassung von The Next Web): Die OSWorld-Lücke von 2,1 Punkten (Computer-Bedienung) geht mit etwa einem Siebtel der Kosten pro Aufgabe einher; Ultrafast-Sol soll "in coming days" folgen.
- **Pro 500:** The Decoder nennt 500 $ im Monat und "höchstes Nutzungskontingent aller Abos", ohne die Zahl 25x (**Tool-Zusammenfassung**); die Angabe "25x usage of Plus" steht auf der Keynote-Folie im Video selbst (Keynote 21:45), ebenso "No 5hr limit" (Bedeutung nicht geprüft). Die Folie bei Keynote 21:53 zeigt nur die Zahlen 100 / 200 / Pro 500. Dass das 200-$-Pro künftig "10x Plus" statt "20x" und weniger GPT-6-Pro-Nachrichten (100 statt 200 pro Woche) umfasst, stammt aus The Decoder (**Tool-Zusammenfassung**), nicht aus der Folie. Die Videobeschreibung sagt, das Pro 200 "kommt zurück". Das ist kein Widerspruch: Laut The Next Web (https://thenextweb.com/news/openai-devday-pro-200-usage-cut-pro-500-plan; **Tool-Zusammenfassung**, im unabhängigen Prüfdurchlauf abgerufen, nicht von mir) wird Pro 200 für Neukunden wieder geöffnet und zugleich auf 10x Plus gekürzt; beides gilt. Die Kürzung beginnt laut derselben Zusammenfassung erst am 30. Oktober; Bestandskunden sind bis 29.10. geschützt (plus 2.500-$-Guthaben). Zum Stand 10.10.2026 gilt "10x Plus" für Bestandskunden also noch nicht.
- **Decisions API:** Die Zahl 150 ms gegenüber 1,6 s steht in der Beschreibung unter Berufung auf The Decoder und wurde dort bestätigt (**Tool-Zusammenfassung**; die 1,6 s gelten dort für die reguläre GPT-6-Luna-API; Modell: GPT-6 Luna, "begrenzte Vorschau"). Dass Roboter sie nutzen könnten, ist die Mutmaßung des Sprechers. Zu Luna (aus Fassung vom 04.10.; Tool-Zusammenfassungen): The Decoder nennt die Grundlage "a version of GPT-6 Luna, its low-cost model"; laut The Next Web erschien Luna am 22.09.2026 zusammen mit GPT-6 Sol. Das Video selbst nennt Luna nur in der eingeblendeten Keynote-Aussage; wie Luna in Qualität und Preis zu Sol und Astra steht, ist offen.

- **Codex-Harness als Open Source:** Simon Willisons Live-Blog verweist auf das Open-Source-Repo github.com/openai/codex (**Tool-Zusammenfassung**); die Ergebniszusammenfassung einer Websuche zu diesem Thema sagt, der Codex-Harness "now powers dots and is open source" (**Suchtreffer**). Der Decoder-Artikel bestätigte die Open-Source-Aussage nicht (nur ein Security-CLI als Open Source). Also: plausibel, nicht sauber belegt.
- **"Sign in with ChatGPT":** Suchtreffer: als "limited preview" mit 16 Integrationen (u. a. Devin, Notion, Vercel), für Plus- und Pro-Abonnenten (**Suchtreffer**). Der abgerufene New-Stack-Artikel enthielt keinen Artikeltext (**nicht abrufbar**). Die Zahl "1,2 Milliarden wöchentliche Nutzer" erscheint auf der Keynote-Folie und in einem Suchtreffer als von Altman wiederholt (**Suchtreffer**); sie ist eine OpenAI-Eigenangabe.
- **Forschungspraktikant:** Die Aussage "über ein Drittel der ganztägigen Aufgaben" deckt sich mit der Folie selbst (Success rate, 8-16-Stunden-Aufgaben, 0 Eingriffe: 10 % Januar, 35 % Juli; im Video gesehen) und mit Simon Willisons Live-Blog (**Tool-Zusammenfassung**). Auch das ist OpenAIs eigene Auswertung. Der Decoder-Artikel zum Thema (**Tool-Zusammenfassung**) nennt: 86 % Erfolg ohne Eingriff bei Aufgaben unter 15 Minuten, bei erfolgreichen Aufgaben von 4-8 Menschenstunden brauchte mehr als die Hälfte mindestens einen menschlichen Schritt; 3,1 Agenten-Arbeitstage je menschlichem Arbeitstag; die Erfolgsprüfung selbst sei eine KI und ihre Verlässlichkeit nicht ausgewiesen; OpenAI räume ein, die Kennzahlen seien "leicht zu erheben, aber schwer zu interpretieren". Die Aussage "KI baut die nächste KI" ist also eine Deutung des Sprechers, nicht das Ergebnis dieser Kennzahlen; OpenAI selbst spricht von Forschungsbeschleunigung (Folientitel "Research acceleration: The view inside OpenAI").
- **Über 100 offene Mathematikprobleme:** Laut TechCrunch (**Tool-Zusammenfassung**) behauptete OpenAI am 21.09.2026, ein internes Modell habe "mehr als 100 weitere offene Probleme" gelöst; wie und von wem das geprüft wurde, stand dort nicht. Im selben Artikel: 25 Fields-Medaillen-Gewinner unterschrieben einen offenen Brief mit Bedenken gegenüber Laboren, die berühmte Probleme lösen wollen; nur ein Beirats-Mitglied unterzeichnete. Das Video sagt, die KI habe "geholfen", Probleme zu lösen, "seit Jahrzehnten offen"; TechCrunch und The Decoder sagen nur "open" bzw. "long-standing" (**Tool-Zusammenfassung**); "seit Jahrzehnten offen" findet sich laut The Next Web (https://thenextweb.com/news/sam-altman-openai-ai-research-intern-devday-keynote; **Tool-Zusammenfassung**, im unabhängigen Prüfdurchlauf abgerufen, nicht von mir): "helped solve more than 100 maths problems that had been open for decades". "Jahrzehnte" ist also nur in dieser einen Quelle belegt, nicht in der Erstquelle der Entdeckung. Das Modell ist ein interner, unveröffentlichter Entwurf; ob es mit Sol, Astra oder einem anderen identisch ist, ist unklar.
- **"Dutzende Bugs pro Tag" bei OpenAI:** Eigenaussage von OpenAI im Keynote-Material, nicht geprüft.
- **Offen: "100 Dollar"-Stufe bei Dots/Pro:** Dieses Video nennt keine Dot-Einzelpreise. Belegt sind Pro 500 (500 $) und das gekürzte Pro 200 (The Decoder, Tool-Zusammenfassung). Die "100-$-Stufe" aus früheren Notizen (laut ki-modellvergleich-kosten.md: 100 $/200 $/500 $-Stufen, Quellen Futurism, Startup Fortune) bleibt ungeklärt; die Folie bei Keynote 21:53 zeigt lediglich die Zahlen 100 und 200 neben Pro 500, ohne gelesenen Preis (aus Fassung vom 04.10., hier mit der Folienbeobachtung ergänzt). Nicht raten.

- **Nicht geprüft:** Programme wie Figma und Photoshop "direkt in ChatGPT" (der Sprecher stellt es als Neuheit dar; ob das schon vor dem DevDay 2026 möglich war, habe ich nicht geprüft); "Custom Rules" für Dots (nur in einer Neuron-Zusammenfassung, **Tool-Zusammenfassung**); Altmans genaue Worte "Zahnräder"; die Zahl "über 4.000 Apps" (laut Beschreibung, Suchtreffer in Drittblogs); die Rust-Demo auf der Bühne (Ergebnis nicht gezeigt, aus Fassung vom 04.10.).
- **Titel/Rahmung:** Der Titel ist sachlich ("sind da" ist für Pro in der EU allerdings nicht zutreffend, siehe Beschreibung). Wertungen wie "geheime Sensation" und "hat mich umgehauen" sind Stil des Kanals.
- **Querverweise (nicht editiert):** gpt-6-astra-ueberblick.md und ki-modellvergleich-kosten.md enthalten bereits einen Nachtrag "DevDay 2026" (Dots, Sol, Ultrafast) auf Basis von video-summary-a_jihWpd8cc.md. Neu gegenüber diesem Nachtrag: (1) Die in den Notizen offene "Namensfrage Sol" lässt sich einordnen: The Next Web beschreibt GPT-6.1 Sol als Nachfolger eines "GPT-6 Sol" (Sol schlägt dort "GPT-6 Sol" um 6,4 Punkte auf DeepSWE; **Tool-Zusammenfassung**); damit wäre GPT-6.1 Sol ein neues Modell, kein anderer Name für "GPT-5.6 Sol". Offen bleibt, ob "GPT-6 Sol" und "GPT-5.6 Sol" (so in gpt-6-astra-ueberblick.md) dasselbe Modell sind; The Next Web erwähnt "GPT-5.6 Sol" nicht (aus Fassung vom 04.10.). Zur Kostennotiz: Der Cached-Preis von 6.1 Sol (0,10 $) sei laut The Next Web (Tool-Zusammenfassung; aus Fassung vom 04.10.) "half of GPT-6 Sol's cached price", daraus lässt sich nur als eigene, unsichere Ableitung vermuten, dass GPT-6 Sol andere Preise hatte als 2 $/10 $ (ein Cached-Preis lässt sich nicht direkt mit Input-/Output-Preisen vergleichen); falls ja, meint "Sol 2 $/10 $" in ki-modellvergleich-kosten.md (Zeile 50 und Abschnitt "GPT-6 Sol/Luna") eher 6.1 Sol oder ist falsch zugeordnet. Offen, nicht geprüft; die Datei wurde nicht geändert. Das "GPT-6 Sol" des Opus-5.5-Vergleichs in video-summary-3xksVVtssjY.md wäre demnach der Vorgänger, nicht dasselbe Modell. (2) Die EU/CH/UK-Einschränkung für Pro steht auch in video-summary-2vTDttP7ELw.md (Z. 42, dort aus dem Video); hier kommt sie aus der Videobeschreibung. (3) Die Pro-Preislage ist durch "Pro 500 = 500 $" und "Pro 200 künftig 10x Plus" (Decoder, **Tool-Zusammenfassung**) etwas klarer, aber weiterhin nicht von OpenAI selbst gesehen. Zum Forschungspraktikanten siehe video-summary-fmMCg6dyWpQ.md (Pachocki: Messlatte "automatisierter Forschungspraktikant" erreicht, vollautonomer KI-Forscher Anfang 2028). Zur Rhetorik "KI baut KI" passt ki-forschungsdurchbrueche-2026.md. Zwei weitere Querverweise (aus Fassung vom 04.10.): video-summary-a_jihWpd8cc.md beschreibt Dots "auf Basis des Modells GPT-6 Astra", video-summary-gmZlkrHvkkk.md berichtet von Dots auf einem älteren Modell mit "Consent Gates" und von der Absage von "GPT-6.1 Astra"; dieses Video nennt das zugrunde liegende Modell der Dots nicht. Hier ist "6.1 Sol" das neue Modell, dort wird "6.1 Astra" abgesagt: Namen auseinanderhalten. Widersprüche zu bestehenden Notizen: keine harten gefunden; offen nur die Modellbasis der Dots (Astra oder älteres Modell) zwischen den beiden genannten Notizen.
- ~~**Mit Abruf belegt (Tool-Zusammenfassung, nicht Volltext):** The Next Web: GPT-6.1 Sol als "upgrade to GPT-6 Sol" (22.09. zusammen mit Luna veröffentlicht), 2/10/0,10 Dollar, fast Astra-Niveau bei einem Fünftel des Preises (sinngemäß), Ultrafast Sol "in coming days", bis 8x in Codex. The Decoder: Decisions API 150 ms gegenüber 1,6 s, Ultrafast 6x Preis (Astra 60/300 Dollar), Pro 500 zu 500 Dollar, Pro 200 reduziert (Nutzung 20-fach auf 10-fach Plus), Luna als "low-cost model" der Decisions API, "Codex Security Cloud". Beides **Tool-Zusammenfassung**~~,

kein Volltext.

- **nicht abrufbar:** OpenAI-Hilfeseite zu Dots (403); damit sind "über 4.000 Apps", Regionsausschluss (EU/CH/UK) und die genaue Plan-Zugehörigkeit nur aus der Videobeschreibung bekannt. Ebenso nicht geprüft: 1,2 Mrd. wöchentliche Nutzer, "dutzende Fehler pro Tag" bei OpenAI, Forschungspraktikant-Zahlen (ein Drittel, über 100 Mathematikprobleme), Altman-Aussage, Rust-Demo, Open-Source-Veröffentlichung der Codex-Ausführung, Figma/Photoshop in ChatGPT.

- **GPT-6 Luna (teilweise geklärt):** The Decoder (Tool-Zusammenfassung): Die Decisions API nutzt "a version of GPT-6 Luna, its low-cost model", die 150 ms werden gegen "GPT-6 Luna through the regular API" (1,6 s) verglichen; TNW (Tool-Zusammenfassung): Luna erschien am 22.09. mit GPT-6 Sol. Das Video selbst nennt Luna nicht. Offen bleibt, wie Luna in Qualität und Preis genau zu Sol und Astra steht.

- **Offen: "100 Dollar"-Dots-Preis:** Dieses Video nennt keine Dot-Einzelpreise. Belegt sind Pro 500 (500 Dollar) und ein gekürzter Pro-200-Plan; die "100-Dollar-Stufe" aus früheren Notizen (Futurism, Startup Fortune) bleibt ungeklärt. Nicht raten.

- **Sprache des Tons:** Die Metadaten führen language = de-DE, die Captions heißen "en-orig" (englisch). Die Tonsprache ist damit nur über Metadaten belegt, nicht durch Anhören.

- **Querverweise (nicht editiert):**

- video-summary-a_jihWpd8cc.md (Satire-Video) behandelt dieselbe Veranstaltung; dessen Aussage "Ultrafast 8x für 6x Preis" ist hier zu präzisieren (Codex 8x, API 6x). Dort werden Dots als "auf Basis von GPT-6-Astra" beschrieben; dieses Video sagt das nicht ausdrücklich.

- gpt-6-astra-ueberblick.md nennt als Vergleichsmodell "GPT-5.6 Sol"; laut TNW ist GPT-6.1 Sol das Upgrade von "GPT-6 Sol". Das Verhältnis "GPT-5.6 Sol" zu "GPT-6 Sol" bleibt ungeklärt. Preise 10/50 Dollar für Astra stimmen mit dem "ein Fünftel"-Verhältnis überein.

- ki-modellvergleich-kosten.md Z. 50: Zuordnung "GPT-6 Sol/Luna 2 $/10 $" vs. "GPT-6.1 Sol": Für **GPT-6.1 Sol** bestätigen Video und TNW 2/10 Dollar; ob die dort genannten 2/10 Dollar für "GPT-6 Sol/Luna" in Wahrheit GPT-6.1 Sol meinen, ist offen. "GPT-6 Sol" aus dem Opus-5.5-Vergleich (video-summary-3xksVVtssjY.md) ist laut TNW der Vorgänger von GPT-6.1 Sol (nicht dasselbe Modell); Preise von GPT-6 Sol sind hier nicht belegt. Hinweis (Tool-Zusammenfassung TNW): Der Cached-Preis von 6.1 Sol (0,10 $) sei "half of GPT-6 Sol's cached price"; GPT-6 Sol hatte demnach vermutlich 0,20 $ und nicht 2 $/10 $. Dann meint "Sol 2 $/10 $" in ki-modellvergleich-kosten.md (Z. 50 und Nachtrag; dort auch "Sol/Luna (2 $/10 $ bzw. 0,10 $/0,50 $)") eher 6.1 Sol oder ist falsch zugeordnet. Offen, nicht geprüft; die Datei wurde nicht geändert.

- video-summary-gmZlkrHvkkk.md verweist auf Pro-200-Kürzung ab 30.10., Pro 500 und die Absage von "GPT-6.1-Astra" (andere Aussage als hier: dort wird ein Modell "6.1-Astra" abgesagt, hier ist "6.1 Sol" das neue Modell); passt zusammen, aber Namen gut auseinanderhalten.

- Widersprüche zu bestehenden Notizen: keine harten gefunden; nur die oben genannten Präzisierungen.