"Meta bringt Muse Wonder Full raus: schlägt GPT-6 Astra und Gemini 4 Argon"

Kanal: AI Revolution auf Deutsch
URL: https://www.youtube.com/watch?v=eDCd4UJParE
Länge: 14:53
Zusammenfassung erstellt: 2026-10-17

Siehe auch: video-summary-_hWLhbHj2Cg.md — beschreibt den Meta/Scale-AI-Deal aus der Finanzierungsperspektive: 14 Mrd. $ für eine Beteiligung, gefolgt von 14 % Belegschaftsabbau bei Scale. Kein Widerspruch, aber eine andere Einordnung: Das dortige Video sieht den Deal als Symptom einer teuren Acquihire-Welle im KI-Sektor, während dieses Video zeigt, was daraus inhaltlich entstanden ist — nämlich ein Modell, das laut unabhängigen Indizes tatsächlich an der Spitze mitspielt.

Worum geht es?

Am 12. Oktober 2026 hat Meta zwei neue KI-Modelle veröffentlicht: **Muse Wonder** und **Muse Wonder Full**. Das ist bemerkenswert, weil Meta — das Unternehmen hinter Facebook, Instagram und WhatsApp — bis vor Kurzem nicht als ernsthafter Mitbewerber in der Spitzenklasse der KI galt. Der Kanal „AI Revolution auf Deutsch" fasst zusammen, was diese Modelle leisten, wie sie sich gegen die Platzhirsche Claude Opus 5.5 (Anthropic), GPT-6 Astra (OpenAI) und Gemini 4 Argon (Google) schlagen — und wie es überhaupt so weit kam, dass Mark Zuckerberg für eine einzige strategische Personalie 14,3 Milliarden Dollar ausgegeben hat.

Neben dem Hauptthema streift das Video zwei weitere Entwicklungen der Woche: OpenAI hat das Standard-Kontextfenster seines Codiertools Codex deutlich ausgeweitet, und KI-Agenten haben innerhalb einer einzigen Nacht ein schwieriges mathematisches Problem auf unerwartete Weise weitergebracht. Diese letzte Geschichte gibt einen ungewohnten Einblick, was Mensch-KI-Zusammenarbeit heute schon in der Grundlagenforschung leisten kann.

Der Weg hierher: Vom Llama-4-Skandal zur Frontier-KI

Vor etwa anderthalb Jahren erschien **Llama 4**, Metas damals neues Sprachmodell. Was folgte, war peinlich: Meta wurde dabei erwischt, für Benchmark-Tests (standardisierte Leistungstests für KI-Modelle) andere Modellvarianten einzusetzen als für die öffentliche Veröffentlichung — die Ergebnisse sahen damit besser aus, als das Produkt wirklich war. Meta wurde seither im Rennen der Frontier-Modelle (Modelle an der absoluten Spitze der KI-Entwicklung) kaum noch ernst genommen.

Zuckerberg reagierte auf seine eigene Art: Er kaufte sich Kompetenz ein. Im Juni 2025 zahlte Meta 14,3 Milliarden Dollar, um **Alexander Wang** — den Gründer des Datenbeschriftungsunternehmens Scale AI, damals 29 Jahre alt und ohne klassische KI-Forschungserfahrung — als **Chief AI Officer** zu verpflichten (die Leitungsposition für die gesamte KI-Strategie). Gleichzeitig entließ Meta rund

600 Mitarbeiter aus dem alten Forschungsbereich. Auch **Yann LeCun** — ein weltberühmter KI-Forscher und Träger des **Turing-Preises** (die höchste Auszeichnung in der Informatik, benannt nach dem britischen Mathematiker Alan Turing) — verließ das Unternehmen im Winter. LeCun hatte Wang öffentlich kritisiert: Er habe keine Forschungserfahrung und verstehe nicht, was Forscher wollen. Wang stimmte dem im Wesentlichen zu — und betrachtet genau das als seinen strategischen Vorteil.

Die neuen Modelle: Muse Wonder und Muse Wonder Full

Nach 14 Monaten Entwicklung in Wangs neuem Labor — dem **Meta Superintelligence Lab** — erscheinen zwei Modelle:

- **Muse Wonder** (kurz: Standard Wonder): Das kleinere der beiden. Direkt über Metas API für Entwickler verfügbar.
- **Muse Wonder Full** (kurz: Full): Das leistungsfähigere Modell. Ausschließlich für Abonnenten von **Muse Code** (Metas Coding-Werkzeug, vergleichbar mit Claude Code von Anthropic) zugänglich — über einen 50-Dollar-Monatsplan (Mehrbenutzer-Lizenz) oder den neuen 200-Dollar-Plan, der 80-mal so viel Nutzungsvolumen bietet wie der günstigste Grundplan.

Beide Modelle besitzen ein **Kontextfenster von einer Million Tokens** (grob gesagt rund 750.000 Wörter — etwa zehn dickere Bücher), nehmen Text, Bilder, Videos und Audiodateien entgegen und geben Antworten ausschließlich als Text zurück. Sie sind ausdrücklich nicht auf schnelle Einzelanfragen ausgelegt — das ist Metas älteres Modell Muse Spark — sondern auf eigenständiges Arbeiten über längere Zeiträume: Programmieraufgaben mit vielen Schritten sowie professionelle Tätigkeiten in Recht und Finanzen. **Muse Wonder Full ist nicht über die API erhältlich** und hat noch kein öffentliches Veröffentlichungsdatum. Metas eigener persönlicher Assistent Meta AI läuft weiterhin auf dem älteren Spark-Modell.

Wo Muse Wonder stark ist

Auf dem **Artificial Analysis Intelligence Index** — einem unabhängigen Vergleich zwischen KI-Modellen — erreicht Muse Wonder Full **56 Punkte**. Das ist gleichauf mit Claude Sonnet 5.5 (laut Video, genaue Zuordnung unsicher — siehe „Zu prüfen") und liegt knapp unter Claude Opus 5.5 (58 Punkte). Deutlich unter diesem Niveau: Claude Fable 5.1, GPT-6 Astra und Gemini 4 Argon liegen alle um die 53 Punkte. Standard Wonder erreicht 52, leicht über GPT 6.1. Metas Vorgängermodell Muse Spark 1.3 hatte erst vor sechs Wochen 48 Punkte — ein Sprung, der manche Online-Kommentatoren spekulieren ließ, ob die großen KI-Labore heimlich selbstverbessernde Systeme einsetzen.

Besonders stark zeigt sich das Modell bei **langen Programmieraufgaben**. Im Benchmark „SWE Marathon" — einem Test, bei dem die KI selbstständig Code liest, Tests ausführt, Fehler findet und so lange weitermacht, bis alles läuft — erreicht Wonder Full 42,5 Prozent. Zum Vergleich: GPT-6 Astra liegt dort bei etwa 5 Prozent. Im Benchmark „DeepSWE" (113 Programmieraufgaben in echten Code-Projekten mit fünf Programmiersprachen) landen Wonder Full bei 79 Prozent und Standard Wonder bei 78,8 Prozent — Claude Opus und GPT-6 Astra liegen beide bei rund 74 Prozent.

Im **Rechtsbereich** fällt die Überlegenheit noch deutlicher aus: In einem unabhängigen Rechtsbenchmark erzielt Wonder Full 13,1 Punkte, Claude Opus lediglich 4,2. Auch im Finanzbereich liegt Wonder Full vorne.

Auffällig ist die Ehrlichkeit des Modells: Bei Fragen, die es nicht sicher beantworten kann, gibt es nur in 23 Prozent der Fälle trotzdem eine Antwort — es **halluziniert** also weniger als die Konkurrenz. GPT-6 Astra halluziniert bei 51 Prozent unsicherer Fragen, Claude Opus bei 59 Prozent. Für ein Modell, das man als verlässlichen digitalen Mitarbeiter einsetzen will, ist das ein praktisch relevanter Unterschied.

In einem direkten Praxistest ließ ein Entwickler beide Modelle dasselbe 3D-Spiel programmieren: Claude Code mit Opus brauchte 11 Minuten 40 Sekunden — Muse Code mit Standard Wonder 3 Minuten 42 Sekunden.

Wo Muse Wonder noch zurückliegt

Das Bild ist nicht einheitlich. Im Benchmark **ProgramBench** — neue Software komplett von Grund auf schreiben — erreicht Wonder Full nur 59 Punkte, während Claude Opus bei 70,5 liegt. Im **Wissens-Test** mit 6.000 Fragen (allgemeines Faktenwissen) schafft Wonder Full 30 Punkte, Standard Wonder 25 — Claude Opus erzielt dort 46, GPT-6 Astra 43, Gemini Argon 42. Die Modelle wissen schlicht weniger über die Welt. Meta räumt selbst ein, dass die Testbedingungen möglicherweise nicht optimal für Konkurrenzmodelle eingestellt waren.

Preise und Verfügbarkeit

Standard Wonder kostet über die API 4 Dollar pro Million Eingabe-Tokens und 20 Dollar pro Million Ausgabe-Tokens — exakt dasselbe wie Claude Opus 5.5. Zum Vergleich: GPT-6 Astra kostet 50 Dollar pro Million Ausgabe-Tokens. Trotzdem sind die durchschnittlichen Kosten pro Aufgabe laut Artificial Analysis höher als bei manchen Konkurrenten: rund 4,52 Dollar bei Wonder gegenüber 3,26 Dollar bei Astra oder 0,99 Dollar bei Gemini Argon. Der Grund: Wonder liest extrem viel — laut Analyse 7,69 Millionen Eingabe-Tokens pro Aufgabe, zwei- bis dreimal so viel wie vergleichbare Modelle von Google und OpenAI. Das macht drei Viertel der Gesamtkosten aus.

Alexander Wang: Kein Forscher, aber ein Zuhörer

Wangs Ansatz war ein bewusster Bruch mit dem Üblichen. Er ist kein KI-Forscher. Er hat ein Jahrzehnt damit verbracht, bei Scale AI Datenbeschriftung zu industrialisieren — also das händische Kennzeichnen von Trainingsdaten, auf die KI-Modelle angewiesen sind. Wang sagt selbst, er sei weder Forscher noch Produktdesigner und war bei Scale AI der Flaschenhals jeder Entscheidung. Bei Meta baut er ein neues Team auf: mit Sign-on-Boni von bis zu 100 Millionen Dollar für Schlüsselpersonen aus OpenAI und Google. Sheng Chao, Absolvent der Tsinghua-Universität, wird leitender KI-Wissenschaftler; Berkeley-Professor Dan Song leitet eine neue Forschungsabteilung. Die Entlassungen im Oktober 2025 trafen das alte Team, nicht Wangs neues.

Wangs strategische Begründung: Die anderen Labore hatten sich auf Codieragenten konzentriert, weil Claude so dominant war. Meta setzte stattdessen auf seine eigene Stärke — Instagram,

WhatsApp, Facebook und deren 3 Milliarden Nutzer. Ein Modell, das den Samstag plant, Versicherungsansprüche bearbeitet und Finanzen verwaltet, braucht andere Fähigkeiten als ein reiner Programmierassistent. Zwei neue technische Konzepte ermöglichen das: **Aktives Gedächtnis** (das Modell speichert wichtige Details und ruft sie Tage oder Wochen später ab) und **Aktiver Fokus** (bei einem Hindernis wählt das Modell einen anderen Ansatz, prüft eigene Fehler und fragt nach, wenn nötig).

Am Rande: OpenAI und Zhipu

OpenAI hat in derselben Woche das Standard-Kontextfenster von GPT-6 in Codex und ChatGPT von 272.000 auf 500.000 Tokens ausgeweitet — rund 80 Prozent mehr, ohne Aufpreis für Abonnenten. Einen ersten Versuch mit 372.000 Tokens im Juli hatte OpenAI zurückziehen müssen, weil Nutzer ihre monatlichen Kontingente zu schnell aufbrauchten. Claude Code verwendet standardmäßig eine Million Tokens und beginnt erst bei rund 967.000 mit dem Komprimieren des Verlaufs.

Das chinesische KI-Unternehmen **Zhipu** testet heimlich das Modell **GLM 5.3 Highspeed** in seinem Coding-Tool ZCode mit ausgewählten Nutzern. Ein Nutzer maß dort über 490 Tokens pro Sekunde — zum Vergleich: DeepSeek 4.1 Flash erreicht rund 121, das Standard-GLM-5.3 rund 71. Für Codieragenten, die pro Aufgabe Dutzende von Modellanfragen stellen, addieren sich wenige Sekunden Wartezeit pro Anfrage schnell zu zehn Minuten Mehraufwand pro Aufgabe.

Das Mathe-Wunder über Nacht

Die ungewöhnlichste Geschichte der Woche: OpenAI betreibt eine Reihe offener mathematischer Herausforderungen namens **Mathdrop**. Aufgabe Nummer 109 dreht sich um einen möglichst effizienten Algorithmus zur Multiplikation sehr großer Zahlen — eines der klassischen ungelösten Probleme der Informatik. Die Güte einer Lösung wird durch einen Wert namens **Kappa** gemessen: je größer, desto besser.

Am frühen Morgen des 8. Oktober verbesserte Forscher Dak Koplik den Wert allein auf 2^(–34) — ein kleiner, aber echter Fortschritt — und twitterte trocken: „Gehe jetzt schlafen. Leider nur kleiner Fortschritt." Während er schlief, beschäftigten sich andere — darunter KI-Agenten auf Basis von OpenAI Codex und Claude — eigenständig mit seinem GitHub-Repository. Innerhalb von 24 Stunden liefen mehr als 260 Millionen Code-Einreichungen ein; Kappa verbesserte sich schließlich auf den Wert 9. 89 Einreichungen stammten von Codex, 48 von Claude — Codex glänzte durch Tempo und Menge, Claude Opus 5.5 erzielte den entscheidenden Qualitätsdurchbruch an der Spitze. Als die Agenten bei einem bestimmten Wert nicht mehr weiterkamen, gab Mathematiker Jacob Susman den nötigen Impuls: Er brachte das Konzept des **E8-Gitters** (die dichtestmögliche Anordnung von Kugeln in acht Dimensionen, ein klassisches Objekt der Geometrie) ein, das den Agenten einen neuen Ansatz eröffnete.

Das Muster ist neu: Mensch und KI-Agenten arbeiten gemeinsam an echter Grundlagenforschung. Der Mensch setzt konzeptuelle Impulse, die KI generiert massenweise Lösungsversuche.

Begriffe

Frontier-Modell: Ein KI-Sprachmodell an der absoluten Leistungsspitze — eines der fähigsten, die es jeweils weltweit gibt. Meta, OpenAI, Anthropic und Google liefern sich ein Rennen darum.

Benchmark: Ein standardisierter Test zur Leistungsmessung von KI-Modellen. Problematisch wird es, wenn ein Unternehmen sein Modell gezielt auf diese Tests trainiert — die Ergebnisse verbessern sich dann, ohne dass das Modell wirklich besser wird (sogenanntes Benchmark-Overfitting).

Token: Die kleinste Einheit, in der ein Sprachmodell Text verarbeitet. Grob gesagt entspricht ein Token rund 0,75 Wörtern. „1 Million Tokens" sind also rund 750.000 Wörter — ungefähr der Umfang von zehn durchschnittlichen Romanen.

Kontextfenster: Die Menge an Text, die ein Modell auf einmal „sehen" und in seiner Antwort berücksichtigen kann. Ein größeres Kontextfenster erlaubt es, ganze Codeprojekte oder sehr lange Dokumente auf einmal zu übergeben.

API (Application Programming Interface): Eine Schnittstelle, über die Entwickler ein KI-Modell direkt in eigene Programme einbauen können — ohne Benutzeroberfläche, per Code angesteuert.

Turing-Preis: Der renommierteste Preis in der Informatik, jährlich von der ACM vergeben. Benannt nach dem britischen Mathematiker Alan Turing. Yann LeCun (Ex-Meta) ist einer der Träger.

Halluzination: Wenn ein KI-Modell eine Antwort erfindet, obwohl es die richtige Antwort nicht kennt, statt einfach zu sagen „ich weiß es nicht". Eine hohe Halluzinationsrate ist ein Qualitätsproblem.

Scale AI: Ein US-amerikanisches Unternehmen, das sich auf Datenbeschriftung spezialisiert hat — also das systematische Kennzeichnen von Trainingsdaten, auf die KI-Modelle zum Lernen angewiesen sind.

E8-Gitter: Eine mathematische Struktur in acht Dimensionen, die als dichtestmögliche Kugelpackung in diesen Dimensionen gilt. Außergewöhnlich symmetrisch und ein bekanntes Objekt in der Mathematik, das hier als konzeptueller Ansatz bei einem KI-gestützten Forschungsproblem diente.

Kernbotschaft

Metas Comeback an der KI-Spitze ist real — und schneller gekommen als erwartet. Muse Wonder Full liegt laut unabhängigen Messungen knapp unter Claude Opus 5.5 und klar vor dem Feld darunter. Besonders stark ist es bei langen Programmieraufgaben, Rechtsfragen und im Umgang mit Unsicherheit: Es sagt häufiger „ich weiß nicht" als die Konkurrenz, statt zu halluzinieren. Erkauft wurde das mit einer ungewöhnlichen Personalstrategie — kein klassischer Forscher an der Spitze, sondern ein Unternehmer mit Datenerfahrung und einem Budget von 14,3 Milliarden Dollar. Wer Muse Code nutzen möchte, bekommt mit dem 50- oder 200-Dollar-Monatsplan Zugang zu Wonder Full; Wonder Standard ist per API verfügbar. Die Nebenstory der Woche — KI-Agenten verbessern über Nacht ein mathematisches Problem, das ein Forscher Jahrzehnte nicht lösen konnte — zeigt, wohin die Reise geht: KI als eigenständiger Mitarbeiter in der Forschung, mit dem Menschen als

Impulsgeber an konzeptuellen Engstellen.

Themen-Tags

Meta, Muse Wonder, Muse Wonder Full, Alexander Wang, Scale AI, Yann LeCun, Frontier-Modell, Benchmark, SWE Marathon, DeepSWE, Artificial Analysis Intelligence Index, Claude Opus 5.5, GPT-6 Astra, Gemini 4 Argon, OpenAI Kontextfenster, Zhipu GLM 5.3, Mathdrop, E8-Gitter, KI-Grundlagenforschung, Halluzination

Zu prüfen

- **Muse Wonder Full: 56 Punkte auf dem Artificial Analysis Intelligence Index — Suchtreffer.** Mehrere Quellen (TechCrunch, ProPakistani, aimagazine.com) bestätigen die Veröffentlichung vom 12. Oktober 2026 und die ungefähren Benchmarks. Die Independent-Analysis-Werte (56 für Wonder Full, ~53 für Fable 5.1/Astra/Argon) decken sich mit dem Transcript. Claude Opus 5.5 liegt laut Artificial Analysis bei 58 — also knapp über Wonder Full, nicht gleichauf. Die Behauptung im Video, Wonder Full sei „gleichwertig mit Claude Sonnet 5.5" (im maschinell übersetzten Transkript als „Klozone 5.5" wiedergegeben), lässt sich nicht eindeutig zuordnen: Gemeint sein könnte eine Sonnet-Klasse bei ähnlichem Score.
- **Mark Zuckerberg zahlt $14,3 Mrd. für Alexander Wang — Suchtreffer.** Bestätigt durch Übereinstimmung mit video-summary-_hWLhbHj2Cg.md ("Meta habe über 14 Mrd. $ für einen großen Anteil an Scale AI gezahlt") sowie dem Websuchtreffer-Kontext. Technisch handelt es sich um eine Beteiligung an Scale AI plus Wangs Einstieg als CAO — kein reines Gehalt.
- **Standard Wonder: $4/$20 pro Million Tokens — Suchtreffer.** pasqualepillitteri.it bestätigt explizit: „Muse Wonder launches at Opus 5.5 prices but trails it in benchmarks". Preise stimmen überein.
- **SWE-Marathon 42,5 % für Wonder Full — Frame-bestätigt, Meta-eigene Zahlen.** Frame 0001 des Videos zeigt ein Diagramm mit „SWE-Marathon"; laut Transkript erreicht Wonder Full ~42,5 %, GPT-6 Astra ca. 5 %, Claude Opus ca. 3 %. Diese Zahlen stammen aus Metas eigenem Benchmark-Bericht und sind nicht unabhängig verifiziert.
- **Zhipu GLM 5.3 Highspeed: 490+ Tokens/Sekunde — nicht abrufbar.** Die Aussage basiert auf einer Nutzermessung laut Transkript, konnte in dieser Zusammenfassung nicht unabhängig geprüft werden.
- **Mathdrop-Wettbewerb: technische Bedeutung von „Kappa = 9" — unklar.** Das Transkript beschreibt einen Kappa-Wert, der „von 2^(–34) auf 9" steigt — die genaue mathematische Bedeutung dieses Wertes im Kontext der Großzahlen-Multiplikation lässt sich aus den maschinell übersetzten Untertiteln nicht eindeutig rekonstruieren. Die Kerngeschichte (KI-Agenten verbessern ein Forschungsproblem über Nacht erheblich) gilt als glaubwürdig.
- **Transkript-Herkunft und Namensverzerrungen:** Das Video ist auf Deutsch gesprochen; die YouTube-Untertitel liegen als maschinenübersetzte englische Auto-Captions vor (393 Segmente). Mehrere Namen sind verzerrt: „Mus Wonder" = „Muse Wonder", „Jan Lequühn" = Yann LeCun, „Grock" = Grok (xAI), „Mus Code" = „Muse Code", „Deeps" = DeepSWE, „Walz" = unbekannter

Benchmark-Anbieter. Diese Zusammenfassung stützt sich auf den englischen Untertitel-Text, sinngemäß und mit Korrekturen ins Deutsche übertragen.

- **Cross-Check mit video-summary-_hWLhbHj2Cg.md:** Dort wird der $14-Mrd.-Scale-AI-Deal als Beispiel für teure Acquihires erwähnt, mit dem Nachsatz, Scale habe kurz danach 14 % der Belegschaft entlassen. Das bestätigt die Größenordnung der Investition, zeigt aber auch, dass Scale AI als Firma danach umstrukturiert wurde. Kein Widerspruch zu den Angaben in diesem Video.

Quelle: video-summary-eDCd4UJParE.md