"Krass: KI kopiert jetzt JEDE Software! Gemini 4 Argon & Meta Wonder im Praxistest | KI-NEWS"

Kanal: Everlast AI (Leonard Schweding)
URL: https://www.youtube.com/watch?v=iVxubkOM4gA
Länge: 29:53
Zusammenfassung erstellt: 2026-10-23

Siehe auch: ki-modellvergleich-kosten.md — Preisvergleich und Benchmark-Überblick aller aktuellen Flaggschiff-Modelle, inkl. Meta Muse Wonder; video-summary-eDCd4UJParE.md — ausführlicherer Test zu Meta Muse Wonder Full/Standard; video-summary-v_USOf1fSYM.md — Überblick zum Claude-Ökosystem (Chat, Cowork, Code) und dem Stand bei Anthropic.

Worum geht es?

In knapp dreißig Minuten liefert Leonard Schweding vom deutschsprachigen Kanal Everlast AI eine dichte Zusammenfassung der wichtigsten KI-Neuigkeiten einer einzigen Woche — und was für eine Woche das war. Gleich mehrere Dinge passierten gleichzeitig: Google veröffentlichte mit **Gemini 4 Argon** ein neues Flaggschiff-Modell, das laut Benchmarks auf Augenhöhe mit den besten Modellen von Anthropic und OpenAI liegt; Meta stellte **Muse Wonder** vor, das in Benchmarks gut aussieht, im Praxistest aber enttäuschte; Anthropic gab bekannt, dass sein internes Entwicklungssystem das bisherige Versionsverwaltungswerkzeug Git ersetzt hat, weil Claude so viel Code schreibt, dass Git nicht mehr mithalten konnte; und der Sprach-Assistent Grok Voice 3.0 übernimmt täglich 20.000 Kundenanrufe für den Satelliten-Internetdienst Starlink.

Das Video ist eine typische "Weekly AI News"-Sendung, kein Tiefen-Tutorial. Es gibt Praxistests und Interviewausschnitte, die abstrakte Konzepte anschaulich machen — etwa einen Klonversuch, bei dem drei KI-Modelle die Business-Software Monday.com nachbauen sollen. Daneben enthält die Folge ein Interview-Segment mit **Tim Gülke**, dem Gründer des Düsseldorfer Startups **Wakeline**, der einen radikal anderen Ansatz zur KI-Entwicklung verfolgt: ohne Deep Learning, dafür mit echter kontinuierlicher Lernfähigkeit.

Am Ende steht eine politische Abrechnung mit der europäischen KI-Strategie: Während Deutschland und die EU über "digitale Souveränität" reden, stammen laut einer OpenAI-Analyse nur 1,5 Prozent aller KI-Agenten-Ausgaben aus Deutschland.

Für Laien ist das Video als Einstieg in aktuelle KI-Entwicklungen gut geeignet, weil es konkrete Demos und Zahlen liefert, statt abstrakt über Modellarchitekturen zu sprechen. Wer verstehen will, was KI-Modelle heute praktisch leisten — und was die Unterschiede zwischen ihnen bedeuten — bekommt hier greifbare Vergleiche. Allerdings hat das wöchentliche Format seinen Preis: Die Tiefe leidet, viele Themen werden nur angetippt, und manches (wie das Quantum-Computing-Beispiel oder das Wakeline-Interview) verdient eine eigene, längere Behandlung.

Gemini 4 Argon: Googles neues Flaggschiff im Detail

Google hat mit Gemini 4 Argon (kurz: Argon) sein aktuelles Top-Modell veröffentlicht. In der Folge erscheint **Sergey Brin**, Mitgründer von Google, der sich nach Jahren wieder aktiv in die Entwicklung der Gemini-Modelle einbringt, in einem Interview-Ausschnitt. Was er dort quasi nebenbei erwähnt, ist nach Einschätzung des Hosts die wichtigste Neuigkeit der Woche: **Google nutzt seine eigenen Modelle inzwischen, um die nächste Modellgeneration zu bauen** — also einen Kreislauf, den Experten als "rekursive Selbstverbesserung" bezeichnen. Vereinfacht ausgedrückt: Das alte Modell hilft dabei, ein besseres Modell zu trainieren, das wiederum hilft, ein noch besseres zu bauen — und dieser Prozess beschleunigt sich.

Brin beschreibt außerdem, was **1 Million Output-Tokens** in der Praxis bedeuten. Ein Token entspricht etwa einem Wort oder Wortfragment. 1 Million Output-Tokens in einem einzigen Schritt zu erzeugen sei das Äquivalent zu etwa einer Woche menschlichen Nachdenkens — mit Pausen sogar einem Monat. Bisherige Modelle konnten zwar in mehreren Schritten insgesamt so viele Tokens erzeugen, aber nicht in einem einzigen Durchgang. Diese Fähigkeit sei besonders wertvoll für Aufgaben, bei denen lange Denkprozesse nötig sind — etwa sehr schwierige Mathematik- oder Planungsprobleme.

Was Argon in der Robotik kann: Laut Google reicht Argon ein einziges Foto einer Tischoberfläche, um daraus eine physikalische Simulation zu erstellen und über 4.500 Trainingsläufe für einen Roboter zu generieren. Damit stieg die Erfolgsrate des Roboters in der realen Welt von 56 auf 75 Prozent. Der humanoide Roboter Apollo des Unternehmens Apptronik traf nach diesem Training sieben Cornhole-Würfe in Folge — nachdem Argon die Bewegung aus einem normalen Video gelernt hatte.

Quantencomputing: Argon hat laut Google einen Baustein für Quantenalgorithmen entwickelt, der mehr als hundertmal weniger Hardware und Rechenzeit benötigt als eine zuvor veröffentlichte Vergleichsmethode — und dessen Korrektheit sogar mathematisch bewiesen wurde. Gleichzeitig hat Argon Googles eigene Fehlerkorrektur für Quantenchips (intern "Alpha Qubit" — im Transkript als "Alpha Cubit" transkribiert) so überarbeitet, dass sie fast doppelt so leistungsfähig ist.

Benchmark-Vergleich mit Claude Opus 5.5: Laut einer DataCamp-Analyse (externe Quelle, nicht im Video genannt; Suchtreffer) gewinnt Argon in 14 von 18 gemeinsamen Benchmark-Tests gegen Claude Opus 5.5. Opus 5.5 liegt vorne in einigen spezifischen Coding-Aufgaben (besonders Terminal-basierte Entwicklung wie FrontierSWE und Terminal-Bench). Das Video vereinfacht das zu "Argon schlägt Opus 5.5" — das stimmt für die Mehrheit der Messungen, aber Fachleute, die schwerpunktmäßig in Terminal-Umgebungen entwickeln, finden Opus 5.5 dort stärker. Was die Benchmarks nicht erfassen, zeigt der nachfolgende Praxistest im Video: Beim Reverse Engineering einer realen Anwendung schneidet Claude Opus 5.5 besser ab als Argon.

Einordnung des Tempos: Brin erwähnt im Gespräch auch, dass Googles Modellentwicklung beschleunigt wird: Nach Gemini 3.6, 3.7 und 3.8 (Flash-Varianten) ist man jetzt bei Version 4. Das Team sieht sich auf einem "RSI-Laufband" — Abkürzung für Repetitive Strain Injury, hier ironisch gemeint: Die Verbesserungen kommen so schnell, dass die Entwickler selbst kaum nachkommen. Diese Einschätzung deckt sich mit dem, was Anthropic intern bereits erlebt.

Nebeninfo: Ein neues, kleineres Modell auf Basis von Gemini 4 — im Transkript als "Gemini Nano 3 Pro" bezeichnet (die automatischen Untertitel garben den genauen Produktnamen) — könnte laut Leaks bald erscheinen. Außerdem ist **Flux 3 Image Small** als Open-Weights-Bildgenerierungsmodell verfügbar, das 4K-Bilder auf einer einzigen GPU erzeugen kann — für alle, die Bildgenerierung lokal betreiben möchten, ohne auf kommerzielle Dienste angewiesen zu sein.

Meta Muse Wonder im Praxistest: Benchmarks vs. Realität

Meta hat ebenfalls ein neues Modell veröffentlicht: **Muse Wonder**. Laut Benchmarks soll es auf Augenhöhe mit Gemini mit Astra und Claude Opus 5.5 liegen. In der Praxis — insbesondere bei 3D-Visualisierungen und Webdesign — enttäuschte es jedoch nach ersten Tests deutlich. Meta gibt dazu an, das Modell schlicht nicht für solche Aufgaben trainiert zu haben, was laut dem Host aber zeigt, wo die Grenzen eines Modells liegen.

Parallel dazu ist **Muse Spark** als Open-Weights-Modell erschienen — also ein Modell, dessen Parameter öffentlich zugänglich sind, sodass es jeder auf eigener Hardware betreiben kann. Allerdings gibt es einen Haken: Wer das Modell von der Plattform Hugging Face herunterladen möchte, muss sich mit Geburtsdatum, Organisation und weiteren persönlichen Daten anmelden. Der Host kritisiert das: Ein wirklich "offenes" Modell sollte keine solchen Zugangshürden haben.

Der große Klonversuch: Wer baut Monday.com am besten nach?

Den greifbarsten und unterhaltsamsten Teil der Folge liefert ein Praxistest von Hosts-Kollege **Marcel**: Drei KI-Modelle sollen die Business-Software **Monday.com** so vollständig wie möglich nachbauen. Monday.com ist ein weit verbreitetes Projektmanagement-Tool — eine Art digitale Schaltzentrale, in der Teams Aufgaben, Deadlines und Pipelines verwalten. Es kostet monatlich Geld pro Nutzer, wie viele vergleichbare Tools.

Marcel gibt jedem Modell denselben Auftrag: Logge dich in Monday.com ein, analysiere die gesamte Oberfläche und baue einen funktionalen Klon. Jedes Modell hat dafür **16 Stunden** Zeit.

Die drei Modelle und ihre Ergebnisse:

Meta Muse Wonder: Klonte insgesamt 49 Seiten der Anwendung. Die Funktionen liefen — aber die Oberfläche sah nicht mehr wie Monday.com aus, sondern wie eine komplett andere App. Ergebnis: Nur halb erfüllt. Der Preis für Muse Wonder ist nicht öffentlich bekannt, da es nur über ein CLI-Abonnement verfügbar ist.

Gemini 4 Argon: Klonte 67 Seiten für **64 US-Dollar**. Funktionalität war gut — aber im Detail offenbarte sich ein kleines Problem: Statt der Original-Icons verwendete Argon farbige Emojis. Das sieht anders aus und zeigt: gut, aber nicht perfekt.

Claude Opus: Klonte ebenfalls zahlreiche Seiten und kostete **257 US-Dollar** — also rund viermal so viel wie Argon. Das Ergebnis war laut Marcel und dem Host kaum vom Original zu unterscheiden: korrekte Farben, korrekte Icons, korrekte Funktionalität. Claude Opus ist damit **klarer Sieger** in

diesem Reverse-Engineering-Test.

Die eigentliche Botschaft des Experiments ist aber weniger, welches Modell am besten ist. Es geht darum, was diese Entwicklung grundsätzlich bedeutet: **Was Entwicklerteams früher Wochen oder Monate gekostet hat, schafft ein KI-Modell in 16 Stunden** — wenn auch mit unterschiedlicher Qualität. Wer heute noch Entwickler für grundlegendes Interface-Reverse-Engineering einstellt, sollte sich fragen, ob das in zwei Jahren noch nötig sein wird.

Anthropic bricht alle Entwicklungsrekorde — und ersetzt Git

Anthropic, das Unternehmen hinter Claude, war diese Woche ebenfalls mit gleich mehreren Meldungen präsent.

Git wird ersetzt: Git ist seit Jahrzehnten das Standardwerkzeug für Versionsverwaltung von Code — so etwas wie ein gemeinsames Notizbuch für alle Änderungen, die Entwicklerinnen und Entwickler am Code vornehmen. Anthropic nutzte es wie fast jedes Technologieunternehmen weltweit. Das Problem: Claude schreibt so viel Code, dass Git nicht mehr mithalten kann. Im Mai 2026 gab es noch rund 2.500 Codeänderungen pro Tag. Im September waren es über 30.000 — das entspricht einer Änderung alle drei Sekunden. Daraufhin bauten sieben Ingenieure ein neues System namens **Scion** (im deutschen Transkript als "Sion" transkribiert; das Wort bedeutet "Sprössling" oder "Ableger"), das laut Angaben rund **200-mal weniger Rechenleistung und Speicher** benötigt als die bisherige Infrastruktur. Das Team bestätigt: Claude schreibt inzwischen besseren Code als die menschlichen Entwickler selbst.

Sicherheitswarnung: Intern — das Transkript nennt hier Anthropic (automatisch als "Infrobic" transkribiert) — wurde gewarnt, dass kleine KI-Modelle sich theoretisch über vernetzte Billig-Geräte wie Fernseher und Haushaltsgeräte eigenständig replizieren könnten, und das innerhalb weniger Monate. Bisher hat kein kleines Modell den gesamten Prozess eigenständig abgeschlossen — aber die Möglichkeit wird als ernstzunehmend eingestuft.

Finanzen und Börsenpläne: Anthropics Quartalsumsatz ist um rund 50 Prozent auf **16,8 Milliarden US-Dollar** gestiegen — ein Wachstum, das die meisten Prognosen von vor einem Jahr weit übertrifft. Das Unternehmen war laut Berichten auf adjusted-Basis in den vergangenen sechs Monaten bereits profitabel. Kurz davor hatte Anthropic vertraulich einen Börsengang bei US-Aufsichtsbehörden angemeldet und plant den Listing für November 2026 (laut externen Berichten; im Video nicht datiert; Suchtreffer). Die Bewertungen, die in Investorenkreisen kursieren, liegen zwischen 1,5 und 2 Billionen US-Dollar — das 2-Billionen-Ziel steht unter Druck, da der annualisierte Umsatz voraussichtlich unter 100 Milliarden bleiben wird. Das Video nennt 1,5 Billionen als "wahrscheinlichere" Größenordnung, was dem unteren Ende der öffentlich diskutierten Bandbreite entspricht.

Grok Voice 3.0: KI-Telefon-Agenten kommen im Massenmarkt an

SpaceX setzt auf den neuen Sprach-Assistenten **Grok Voice 3.0** von xAI (Elon Musks KI-Unternehmen), um täglich rund **20.000 Kundenanrufe** des Satelliten-Internets Starlink zu

bearbeiten. 70 Prozent davon werden vollständig ohne menschliche Beteiligung abgeschlossen. Das ist kein Pilotprojekt mehr — das ist Skalierung im Industriemaßstab.

Was das für Kosten bedeutet, macht der Host konkret: Grok Voice 3.0 kostet rund 7–8 Cent pro Minute (laut unabhängigen Quellen eher 8 Cent, das Video nannte 7 Cent). Im Jahr 2024 lagen die Preise für vergleichbare Sprach-KI-Systeme noch bei 30 Cent pro Sekunde — also etwa 18 Euro pro Minute. Ein menschlicher Callcenter-Agent hat in den letzten Jahren also um bis zu Faktor 13 mehr gekostet als ein KI-Agent heute. Und der Preis sinkt weiter: Nach Schätzung des Hosts könnten die Kosten schon im nächsten Jahr bei 0,5 Cent pro Minute liegen — für 200 Euro im Monat ließe sich dann ein KI-Telefonagent rund um die Uhr betreiben.

Der Host zeigt, wie einfach die Einrichtung geworden ist: Im XAI Developer Console wählt man "Agent erstellen", beschreibt in natürlicher Sprache, was der Agent tun soll (z. B. "Erstlevel-Kundensupport auf Deutsch für einen HiFi-Online-Shop"), und Grok konfiguriert den Rest automatisch — inklusive optionaler Anbindung an Kalender, E-Mail und externe Tools über MCP-Server. Ein kurzer Live-Test im Video zeigt den Agenten in Aktion: Er antwortet auf Produktfragen mit echten Preisen und Spezifikationen direkt von der verlinkten Shop-Website, gibt auf Nachfrage technische Details und nennt korrekt die Garantiebedingungen des Shops. Die Einrichtung dauerte im Demo weniger als zwei Minuten.

Ein wichtiger Hinweis des Hosts: Grok Voice ist zwar für Tests ideal, für den produktiven Einsatz in Deutschland und der EU empfiehlt er **GPT Live** (OpenAIs Sprach-API), weil es DSGVO-konform ist. Die aktuelle Version kostet rund 5 Cent pro Minute, zusammen mit einem leichtgewichtigen Reasoning-Modell (laut Transkript "GPT-6 Luna Medium") ergibt sich ein Gesamtpreis von rund 5,3 Cent pro Minute. Das Modell kann dabei keine neuen Informationen in Echtzeit abrufen — dafür ist ein zweites, denkendes Modell im Hintergrund nötig, das z. B. über Tools auf aktuelle Daten zugreift.

Das zweite Sprach-Demo im Video ist "**Jarvis**" — ein persönlicher Assistent, den das Team für Unternehmenskunden baut. Jarvis begrüßt den Host am Morgen, zählt Termine auf, nennt den wichtigsten Lead im CRM-System (Thomas Müller, Score 92), übernimmt Aufgaben auf Zuruf ("Kümmere dich um Müller GmbH") und zeigt auf Wunsch den Pipelinestatus mit tatsächlichen Umsatzzahlen aus dem CRM an. Dieser Assistent kombiniert Voice mit CRM, Kalender und E-Mail — kein einzelnes Werkzeug, sondern ein koordinierender Agent. Es ist kein Science-Fiction-Szenario mehr: Diese Systeme laufen laut dem Host bereits bei echten Kunden, und ein ausführliches Tutorial für den Eigenbau soll in den kommenden Wochen auf dem Kanal folgen.

Wakeline: KI ohne Deep Learning — ein Düsseldorfer Gegenmodell

Einer der interessantesten Teile der Folge ist ein Interview-Ausschnitt mit **Dr. Tim Gülke**, Gründer des Düsseldorfer Startups **Wakeline**. Gülke hat eine ungewöhnliche Biografie: Er war 2007 Teil des deutschen Teams beim legendären DARPA Urban Challenge — einem Wettbewerb, bei dem ein VW Passat vollständig autonom durch eine Stadt fahren musste. Er promovierte in Aachen und arbeitete anschließend über zehn Jahre lang bei Volkswagen.

Sein Düsseldorfer Startup verfolgt nun einen Ansatz, der dem Mainstream der KI-Branche widerspricht. Die Kernthese: **Die Annahme, dass mehr Daten und mehr Rechenleistung**

automatisch zu besseren Entscheidungen führen, ist die gefährlichste Fehlkalkulation der Branche.

Das Problem mit heutigen großen Sprachmodellen wie GPT, Claude oder Gemini, so Gülke: Sie werden intensiv vortrainiert, dann eingefroren — und dann eingesetzt. Alles, was das Modell weiß, stammt aus dem Trainingsdatensatz. Wenn sich die Welt nach dem Training ändert — ob Maschinenparameter in einer Fabrik, Wetterbedingungen, Marktentwicklungen oder neue Regeln — merkt das Modell es nicht. Es arbeitet immer noch mit dem Stand von gestern. Das kann in bestimmten Anwendungen zu systematisch schlechteren Entscheidungen führen als ältere, aber anpassungsfähige Software.

Wakeframes Ansatz: Statt eines riesigen vortrainierten Modells setzt Wakeline auf ein System, das **während des Einsatzes lernt** — ohne klassische separate Trainingsphase. Das System startet in einer Umgebung, beobachtet Datenströme, stellt Hypothesen auf, testet sie und passt sein Verhalten entsprechend an. Gülke beschreibt den Vorgang konkret: Das System "schaut sich die Umgebung an, was für Regeln gelten, was für Hypothesen kann ich aufstellen, testet diese, verwirft sie wieder, und versucht so immer nah an der Realität zu bleiben." Es ist "stateful" — hat also einen internen Zustand, der sich ständig aktualisiert. Gülke vergleicht das mit kleinen Lebewesen: Eine Ameise hat kein Rechenzentrum im Rücken, aber sie lernt und überlebt in neuen Umgebungen.

Dieses Konzept ist nicht neu — es ähnelt klassischen **Reinforcement-Learning**-Ansätzen und adaptiven Steuerungssystemen aus der Robotik. Was Wakeline beansprucht: Es ohne Deep Learning umzusetzen, also ohne neuronale Netze im klassischen Sinne. Wichtig: Das bedeutet nicht, dass das System untrainiert startet. Es kann aus historischen Daten lernen — aber eben nicht in dem Sinne, dass die Gewichte eines neuronalen Netzes durch Millionen von Backpropagation-Schritten eingestellt werden. Die Trennung zwischen "Trainingsphase" und "Betriebsphase" entfällt.

Für wen ist das relevant? Vor allem für Anwendungen, bei denen sich die Umgebung ständig ändert — Industriemaschinen, individuelle Wetterbedingungen, spezifische Marktdaten oder Steuerungssysteme, bei denen ein Modell, das "von gestern" stammt, gefährlich falsch liegen kann. Das vollständige Interview erscheint laut Ankündigung auf dem Schwester-Kanal "KI Bubble".

Deutschland und Europa abgehängt: Die Zahlen der KI-Realnutzung

Das "Diagramm der Woche" der Folge kommt aus einer OpenAI-eigenen Analyse zur Verbreitung von KI-Agenten in Europa.

Die Schlagzeile klingt zunächst gut: Seit Mai 2026 gibt es **8,1-mal mehr kleine und mittlere Unternehmen** in Europa, die KI-Agenten von OpenAI einsetzen. Aber der Host blickt tiefer.

Das eigentliche Problem: Insgesamt stammen nur **10 Prozent aller Output-Tokens** (also aller KI-Ausgaben in agentischen Workflows) aus der EU — trotz der Wirtschaftsgröße der Region. Der Rest kommt aus Nordamerika, Asien-Pazifik und anderen Regionen. Ein "agentischer Output-Token" entsteht, wenn ein KI-Agent tatsächlich Schritte ausführt — also nicht nur eine Frage im Chat beantwortet, sondern Aufgaben durchführt, Code ausführt, Daten verarbeitet, Entscheidungen trifft.

Diese Unterscheidung ist entscheidend: "ChatGPT benutzen" und "KI-Agenten einsetzen" sind zwei sehr verschiedene Dinge.

Deutschland speziell: Nur **1,5 Prozent** der agentischen KI-Tokens kommen aus Deutschland. Das Land liegt damit hinter der Slowakei, Belgien, den Niederlanden, Ungarn, Zypern und Litauen. Während deutsche Politiker regelmäßig betonen, wie weit Deutschland bei der KI-Adoption sei, zeigen die Nutzungsdaten etwas anderes: Viele meinen mit "KI einsetzen" das Tippen in einen ChatGPT-Chat — keine automatisierten, agentengesteuerten Workflows, die Prozesse wirklich verändern.

Der Host formuliert seine Hypothese direkt: Die überwiegende Mehrheit der Unternehmen und Entscheider hat noch nicht verstanden, was mit KI-Agenten überhaupt möglich ist — und die Zahlen bestätigen das in Schwarz und Weiß.

Politischer Teil — EU-Reaktionen: Der Host listet mehrere EU-Maßnahmen, die er kritisch bewertet:

- Die EU bereitet sich auf einen Sicherheitsvorfall ähnlich dem "Hugging-Face-Vorfall" vor und beruft ein Gremium aus 60 Experten.
- Aus Brüssel kommen Diskussionen über eine **7-prozentige Umsatzsteuer** auf KI-Dienste, um sich vor "unkontrollierten KI-Agenten" zu schützen.
- Es werden **Petabytes an Agenten-Sitzungsdaten** von OpenAI und Anthropic analysiert.
- Es gibt Überlegungen zu einer **KI-Steuer** auf US-Konzerne, um ein zukünftiges Grundeinkommen zu finanzieren.

Der Host führt zwei neue Begriffe ein, um diese Dynamik zu beschreiben:

> **Sovereignty Washing** (in Anlehnung an "Greenwashing"): Wenn Regierungen oder Institutionen den Kauf von Infrastruktur-Kapazitäten oder das Abonnieren eines französischen KI-Labs als "digitale Souveränität" verkaufen — obwohl die eigentliche Technologiemacht woanders liegt. So wie McDonald's sein Logo in Europa grün färbte, ohne grüner zu werden, betreiben Institutionen Sovereignty Washing, wenn sie sich als souverän darstellen, obwohl sie die Infrastruktur leasen und die Modelle importieren.
>
> **Sovereignty Arbitrage**: Die Strategie eines KI-Unternehmens, die Lücke zwischen gefühlter und tatsächlicher Souveränität — sowie zwischen inszenierter und echter Modell-Performance — in Marktanteile, Subventionen und Industrieverträge umzuwandeln.

Als Beispiel nennt der Host eine Schlagzeile: Deutschland und Nvidia haben eine Zusammenarbeit angekündigt, bei der ein "dreistelliger Millionenbetrag" in KI-Rechenleistung investiert wird. Der Host kommentiert: Das entspricht in den USA dem, was ein mittleres Unternehmen für einen monatlichen Infrastruktur-Stromvertrag ausgibt. Und: Die Infrastruktur bleibt im Besitz von Nvidia, nicht von Deutschland.

Ergänzend zitiert der Host **Arthur Mensch**, CEO von Mistral (dem größten europäischen KI-Labor), der in einem Blogbeitrag schreibt, Europa fühle sich an wie eine Region, die dabei ist aufzugeben und zu sagen: Das Spiel ist vorbei, wir sollten mit eigenen KI-Modellen aufhören. Mensch hält das

für einen fundamentalen Fehler — dem Host zufolge zu Recht. Dieses Zitat ist bemerkenswert, weil Mensch selbst das stärkste europäische Argument für eigenständige KI-Entwicklung verkörpert und gleichzeitig eingesteht, dass die Stimmung in Europa kippt.

Datenschätze als neues Geschäftsmodell

Ein kurzes Segment widmet sich einer wenig beachteten wirtschaftlichen Chance: **Unternehmensdaten** als Verkaufsware für KI-Labore.

KI-Labore brauchen qualitativ hochwertige, spezialisierte Trainingsdaten — und zahlen dafür. Laut dem Video verdienen manche Datenanbieter monatlich zehn Millionen Dollar oder mehr, indem sie Datensätze an KI-Unternehmen verkaufen. Als Beispiel wird **Klett AI** erwähnt, das offenbar einen Marktplatz für solche Datensätze aufbaut (der Host betont, keine Kooperation mit dem Unternehmen zu haben).

Die Kernbotschaft: Unternehmen, die überlegen zu verkaufen — etwa wegen fehlender Nachfolge — sollten prüfen, ob ihr Datenschatz wertvoller sein könnte als das gesamte übrige Unternehmen. Das trifft besonders auf Firmen zu, die über viele Jahre branchenspezifische Prozess-, Maschinen- oder Kundendaten gesammelt haben.

Der Ratschlag bleibt pragmatisch: Eigene Daten an KI-Labore zu verkaufen, ist nur im Exit-Szenario sinnvoll — wer aktiv im Markt ist, sollte seine wichtigsten Unternehmensdaten nicht leichtfertig herausgeben.

Begriffe

Gemini 4 Argon: Googles aktuelles Flaggschiff-Sprachmodell (Stand Oktober 2026). "Argon" ist der interne Codename — benannt nach dem chemischen Element Argon (Ordnungszahl 18). Das Modell ist für komplexe Denk- und Planungsaufgaben ausgelegt und soll erstmals 1 Million Output-Tokens in einem einzigen Durchgang erzeugen können.

Output-Token: Eine Maßeinheit für KI-Textausgaben. Ein Token entspricht grob einem Wort oder Wortfragment. "1 Million Output-Tokens" sind also etwa 750.000 Wörter — oder der Umfang mehrerer langer Romane. Je mehr Tokens ein Modell auf einmal erzeugen kann, desto länger kann es an einem Problem "denken", bevor es antwortet.

Rekursive Selbstverbesserung: Ein Prozess, bei dem ein KI-Modell beim Training seines Nachfolgers hilft — der wiederum beim Training des übernächsten hilft, und so weiter. Google hat nach Aussage von Sergey Brin dieses Modell intern bereits in Betrieb. Die Sorge: Wenn sich Modelle schnell genug verbessern, könnten Menschen die Entwicklung nicht mehr kontrollieren oder nachvollziehen.

Reverse Engineering: Das Analysieren und Nachbauen von Software oder Produkten, ohne Zugang zum Originalcode. In diesem Video: KI analysiert eine laufende Webanwendung (Monday.com) und erstellt anschließend eine möglichst originalgetreue Kopie. Früher benötigte ein Entwicklerteam dafür Wochen; im Test schaffen es KI-Modelle in 16 Stunden.

Sprach-Agent / Voice Agent: Ein KI-System, das Telefongespräche in Echtzeit führt — zuhört, versteht und antwortet. Es kombiniert Spracherkennung (Audio → Text), ein Sprachmodell (Text → Antwort) und Sprachsynthese (Text → Sprache). Moderne Voice Agents klingen für die meisten Menschen kaum noch von einem menschlichen Call-Center-Mitarbeiter zu unterscheiden.

Open Weights: Ein KI-Modell, dessen trainierte Parameter öffentlich veröffentlicht werden, sodass jeder sie herunterladen und auf eigener Hardware betreiben kann. Das Gegenteil ist ein proprietäres Modell, das nur über eine API des Herstellers nutzbar ist. Open-Weights-Modelle bieten mehr Kontrolle und Datenschutz, setzen aber technisches Know-how und entsprechende Hardware voraus.

Deep Learning: Die heute dominierende Methode, KI zu trainieren: Neuronale Netze — lose angelehnt an die Struktur des menschlichen Gehirns — werden mit riesigen Datenmengen gefüttert, bis sie lernen, Muster zu erkennen. GPT, Claude, Gemini — alle basieren darauf. Wakelines Ansatz verzichtet bewusst darauf.

Stateful / Zustandsbehaftet: Ein System, das sich vergangene Ereignisse "merkt" und seinen aktuellen Zustand entsprechend anpasst — im Gegensatz zu zustandslosen Systemen, die jede Anfrage isoliert behandeln. Wakefields kontinuierlich lernende Systeme sind explizit "stateful": Sie akkumulieren Erfahrungen aus dem laufenden Betrieb.

DSGVO-konform: Entspricht der EU-Datenschutz-Grundverordnung. Für Unternehmen in Deutschland und der EU wichtig: Verarbeitung von Kundendaten durch KI-Dienste (z. B. Sprach-Agenten) muss DSGVO-konform sein — das schließt z. B. aus, Gespräche auf Servern außerhalb der EU ohne entsprechende Schutzmaßnahmen zu speichern. GPT Live ist laut dem Video DSGVO-konform; Grok Voice empfiehlt der Host nur für Tests, nicht für den Produktiveinsatz in der EU.

Sovereignty Washing: Neologismus des Hosts: Wenn KI-Investitionen oder -Abonnements als "digitale Souveränität" vermarktet werden, obwohl die eigentliche Kontrolle über Modelle und Infrastruktur weiterhin bei US- oder anderen ausländischen Unternehmen liegt.

Kernbotschaft

Die Woche, die dieses Video zusammenfasst, zeigt exemplarisch, wie sich der KI-Markt 2026 entwickelt: Die Abstände zwischen Flaggschiff-Modellen werden enger — Gemini 4 Argon, Claude Opus 5.5 und Meta Muse Wonder sind alle eng beieinander, wobei sich die Stärken je nach Aufgabe unterscheiden. Der Praxistest mit Monday.com illustriert aber, dass benchmark-starke Modelle nicht immer die beste Nutzererfahrung liefern: Claude Opus war viermal teurer als Gemini Argon, lieferte dafür aber ein Ergebnis, das kaum vom Original zu unterscheiden ist.

Dahinter steht ein struktureller Wandel: KI schreibt bei Anthropic intern schon besser Code als die menschlichen Entwickler, ersetzt Git-Infrastruktur die seit Jahrzehnten Standard war, und übernimmt 20.000 Kundengespräche täglich. Das ist keine Zukunftsvision — das passiert gerade. Gleichzeitig zeigen die EU-Nutzungsdaten, dass Europa — und besonders Deutschland — bei der tatsächlichen Adoption von KI-Agenten weit hinter seinen Möglichkeiten zurückbleibt. Die Lücke zwischen Rhetorik

und Realität ist das vielleicht eigentliche Thema dieser Folge.

Tim Gülkes Wakeline ist dabei eine wichtige Kontraperspektive: Nicht alle glauben, dass der Weg zu besserer KI über immer größere Modelle und immer mehr Trainingsdaten führt. Der Ansatz, Systeme zu bauen, die während des Einsatzes lernen statt zuvor eingefroren zu werden, könnte für bestimmte Anwendungsbereiche der bessere Weg sein — auch wenn er im Mainstream der Branche derzeit wenig Aufmerksamkeit bekommt.

Themen-Tags

Everlast AI, Leonard Schweding, Gemini 4 Argon, Sergey Brin, 1 Million Output-Tokens, rekursive Selbstverbesserung, Quantencomputing, Apptronik Apollo, Robotik, Meta Muse Wonder, Meta Muse Spark, Open Weights, Monday.com Klon, Reverse Engineering, Claude Opus, Marcel, Wakeline, Tim Gülke, Deep Learning, kontinuierliches Lernen, stateful AI, DARPA Urban Challenge, Volkswagen, Grok Voice 3.0, xAI, SpaceX, Starlink, Voice Agent, Jarvis, GPT Live, DSGVO, Sprach-Agenten, Anthropic, Scion, Git, Claude Code, Anthropic IPO, KI-Umsatz, EU AI-Adoption, Deutschland KI-Nutzung, OpenAI Europa-Analyse, Sovereignty Washing, Sovereignty Arbitrage, Arthur Mensch, Mistral, Klett AI, Datenmärkte, Flux 3 Image Small, Hugging Face, Benchmark

---

Zu prüfen

Gemini 4 Argon schlägt Claude Opus 5.5 laut Benchmarks: Teilweise bestätigt — laut DataCamp gewinnt Argon in 14 von 18 gemeinsamen Benchmarks gegen Opus 5.5. In einigen wichtigen Coding-Aufgaben (Terminal-Bench, FrontierSWE) liegt Opus 5.5 vorne. Das Video vereinfacht: "Argon schlägt Opus 5.5" ist nicht falsch, aber nicht vollständig — es ist ein Teilergebnis. Label: **Suchtreffer (Split-Ergebnis).**

1 Million Output-Tokens in einem einzigen Durchgang: Im Video als absolute Neuheit dargestellt, mit Verweis auf Sergey Brin. Die Aussage stammt aus einem Interview-Ausschnitt und ist inhaltlich spezifisch (ein Schritt, nicht mehrere). Nicht über externe Quellen verifiziert, aber Brins Beschreibung ist im Video zitatfähig belegt. Label: **nicht abrufbar (Primärquelle: Video-Interview).**

Anthropic ersetzt Git durch Scion / Sion: Bestätigt durch mehrere Medienberichte (u. a. Vincentschmalbach.com, EdgeX, CryptoBriefing). Sicher: 30.000+ Änderungen/Tag (September 2026), gegenüber 2.500/Tag im Mai 2026. Der Systemname "Scion" ist weitgehend bestätigt; das Transkript nennt "Sion" — Transkriptions-Artefakt der deutschen automatischen Untertitel. Label: **Suchtreffer.**

Grok Voice 3.0 — 20.000 Starlink-Anrufe täglich, 70 % autonom: Bestätigt durch xAI-eigene Fallstudie auf x.ai/stories/starlink und Berichte von CryptoBriefing und anderen. Eine frühere Zahl nannte 15.000/Tag; die aktuelle Zahl von ~20.000 stammt aus einer neueren Unternehmensangabe. 70 % Autonomie-Quote ist zitiert aber nicht unabhängig verifiziert. Label: **Suchtreffer (Kernzahlen bestätigt).**

Preis Grok Voice 3.0 — 7 Cent/Minute: Das Video nennt 7 Cent. Mehrere unabhängige Quellen (darunter eine deutsche Fachseite und offizielle xAI-Angaben) nennen **8 Cent pro Minute**. Minor Discrepancy — möglicherweise handelt es sich um eine gerundete oder ältere Preisangabe im Video. Label: **Suchtreffer (leichte Abweichung: 7 statt 8 Cent).**

Anthropic Quartalsumsatz 16,8 Milliarden US-Dollar (+50%): Bestätigt durch mehrere Quellen (Euronews: +46%, AFP/The Edge Malaysia: ~50%). Die Bewertungsdiskussion läuft laut Reuters zwischen 1,5 und 2 Billionen US-Dollar. Das Video sagt "nur noch 1,5 Billionen wahrscheinlich" — das deckt sich mit dem unteren Bereich der Diskussion. Das $2-Billionen-Ziel als vollständig "vom Tisch" ist etwas zu apodiktisch; es ist das ursprüngliche Ziel, das unter Druck steht. Label: **Suchtreffer (Umsatz bestätigt, Bewertungs-Framing leicht vereinfacht).**

Argon generiert 4.500 Trainingsläufe aus einem Tischfoto, Roboter-Erfolgsrate von 56 auf 75 %: Angaben aus dem Google-eigenen Launch-Material (im Video als Zitat präsentiert). Nicht über unabhängige Quellen verifiziert. Label: **nicht abrufbar (Primärquelle: Google-Eigen-Ankündigung).**

Argon — Quantenalgorithmus mit 100x weniger Hardware: Google-eigene Angabe laut Video, keine unabhängige Verifikation über Suche gefunden. Label: **nicht abrufbar.**

EU: 10 % aller Output-Tokens, Deutschland 1,5 %: Aus einer internen OpenAI-Geschäftsanalyse ("European Business Analysis"), die im Video gezeigt wird. Keine öffentlich zugängliche Primärquelle gefunden. Die Zahlen sind plausibel angesichts bekannter europäischer Adoptionstücke, aber nicht unabhängig verifizierbar. Label: **nicht abrufbar (intern bei OpenAI).**

Kleine KI-Modelle könnten sich innerhalb von Monaten auf Haushaltsgeräten replizieren: Aus einer internen Warnung bei Anthropic laut Video. Die grundlegende Besorgnis über Modell-Replikation über vernetzte Geräte ist ein bekanntes Sicherheitsforschungsfeld. Die spezifische "wenige Monate"-Angabe wurde nicht verifiziert. Label: **nicht abrufbar.**

Cross-Check mit bestehenden Dateien:

- ki-modellvergleich-kosten.md enthält bereits Einträge zu Meta Muse Wonder (aus dem Nachtrag 2026-10-17 zu video-summary-eDCd4UJParE.md) — kein Widerspruch; das vorliegende Video bestätigt die Enttäuschung bei Web-/3D-Aufgaben.
- video-summary-v_USOf1fSYM.md beschreibt Anthropics Entwicklung von Claude Code und Cowork — kein Widerspruch zu den Code-Volumen-Zahlen; das neue Video fügt konkrete Zahlen hinzu.
- Kein Eintrag zu Grok Voice 3.0 oder Wakeline in bestehenden Dateien — Ersterwähnung im Repo.

Quelle: video-summary-iVxubkOM4gA.md