

"Wahnsinn: Hermes-Agent + Qwen"

Kanal: c't 3003

URL: <https://www.youtube.com/watch?v=Ne2UH682x9I>

Länge: 29:14

Zusammenfassung erstellt: 2026-08-22

Siehe auch: [lokale-ki.md](#) für das übergeordnete Thema "lokale KI", [video-summary- Z8W21qUCjo.md](#) für eine Hardware-Benchmark-Serie zu lokalen KI-Boxen (DGX Spark/Strix Halo/Mac Studio), sowie [video-summary-tK9C3Sskws.md](#), [video-summary-8NSyl-npJCU.md](#) und [video-summary-4NqKZerJpk8.md](#) für frühere Hermes-Agent-Erwähnungen im Repo. Details siehe "Zu prüfen".

Worum es geht

Moderator ist Jan-Keno Janßen ("Keno", c't 3003 — bestätigt durch im Video sichtbare Terminal-Pfade wie `/home/keno3003` und den Telegram-Bot-Namen "DemKenoSeinHermes"). Das Video ist explizit Antwort auf zwei häufig wiederkehrende Zuschauerwünsche aus den Kommentaren: mehr zu Hermes Agent und mehr zu lokalen KI-Modellen — beide Themen werden hier kombiniert.

Zentrale Demo direkt zu Beginn: Keno zieht sein Internetkabel physisch aus dem Router, während ihm der KI-Agent Hermes live weitere Aufgaben erledigt (Bild im Netz suchen, als Desktop-Hintergrund setzen, Desktop-Umgebung wechseln) — als Beweis, dass das Sprachmodell komplett lokal läuft, ohne Cloud-Anbindung.

Was ist Hermes Agent?

- Ein **KI-Agent** (nicht nur Chatbot): kann selbst Dinge auf dem Rechner tun statt nur Text/Bilder zurückzugeben — komplette Computerbedienung.
- Kommunikation in natürlicher Sprache, auch per Sprachnachricht, ankoppelbar an Messenger (im Video: Telegram, laut Keno am schnellsten eingerichtet — "drei Sekunden").
- Läuft auf Linux, macOS, Windows; per Kommandozeile oder optionaler grafischer Oberfläche. Keno nutzt im Video primär die CLI und Telegram.
- Funktioniert am besten bei textbasierten/Terminal-Aufgaben; bei grafischen Oberflächen/Websites (Screenshot machen → ans LLM schicken → Klickposition bestimmen) deutlich schwächer und sehr tokenhungrig.
- Entwickelt von **Nous Research** (New York, aus der Krypto-Welt kommend, seit längerem in der lokalen-LLM-Szene aktiv, u. a. mit unzensierten Modellen) — laut Keno noch eine kleine Firma. Open Source, MIT-Lizenz, laut Keno "permanent selbstverbessernd" (merkt sich erfolgreiche Werkzeugaufrufe, baut sich bei Bedarf selbst neue Skills).

Hermes Agent vs. OpenClaw

Keno vergleicht Hermes explizit mit OpenClaw (das er nach eigener Aussage in einem früheren, hier nicht näher spezifizierten Video schon behandelt hat):

Aspekt	Hermes Agent	OpenClaw
Lizenz	Open Source, MIT	Open Source, MIT
Autonomie	laut Keno autonomer, bringt Dinge öfter selbstständig zu Ende	öfter manuelles Nachsteuern nötig ("versuch's nochmal")
Token-Sparsamkeit	stärker optimiert	weniger optimiert
Skills	schreibt sich Skills lieber selbst	mehr vorgefertigte Skills über eigene "ClawHub"-Datenbank
Auftreten	"technischer", zeigt Terminal-Aufrufe offen im Messenger	versteckt technische Schritte eher, "cosplayt einen Menschen"
Security-Ansatz	von Anfang an mitgedacht (neueres Projekt)	ursprünglich privates Hobbyprojekt ohne Security-Fokus, inzwischen verbessert
Interne Technik	nutzt intern bevorzugt Python	eigene, im Transkript unklar wiedergegebene Detailaussage zu Custom-Syntax/Tool-Calling (siehe "Zu prüfen")

Wichtiger Kontext, den Keno selbst einordnet: OpenClaw-Entwickler **Peter Steinberger** (Österreicher) arbeitet inzwischen bei OpenAI; OpenClaw bleibt offiziell kein OpenAI-Projekt und Open Source, wird von manchen Nutzern seitdem aber skeptischer gesehen. **Per Websuche bestätigt:** Steinberger ist im Februar 2026 tatsächlich zu OpenAI gewechselt, OpenClaw wurde laut mehreren Quellen in eine von OpenAI unterstützte Stiftung überführt und bleibt Open Source.

Testumgebung und Sicherheitshinweis

- Getestet auf einem **komplett blanken System** (CachyOS/Linux) auf einem Framework Desktop — explizit NICHT auf einem Produktivsystem mit wichtigen Daten, weil Hermes vollen Systemzugriff hat.
- Mehrfach im Video wiederholte Warnung: agentische Systeme mit vollem Zugriff nur auf Rechnern verwenden, bei denen Datenverlust oder Datenabfluss egal wäre — Stichwort **Prompt Injections** (versteckte Anweisungen aus dem Netz). Keno selbst sind im Test keine (bewusst wahrgenommenen) Prompt Injections begegnet.
- Kleinere lokale Modelle wie das hier verwendete 27B-Modell gelten laut Keno als anfälliger für Prompt Injection als große Cloud-Modelle.

Demos im Video

- **Wetterabfrage** über Telegram — Hermes ruft `curl wttr.in/Hannover` auf und antwortet mit aktuellem Wetter (das Sprachmodell selbst hat kein Internet, Hermes als Agent schon — Kombination aus lokaler "Intelligenz" und Internetzugriff über den Agenten).
- **Mitarbeiterschulung/Compliance-Test** (Multiple-Choice-Fragen auf einer externen Website) automatisiert durchgeklickt — funktionierte am Ende, aber sehr umständlich: durch die screenshot-basierte Websiteanalyse lief der Kontextspeicher ständig voll und musste wiederholt komprimiert werden (im Frame sichtbar: "Session compressed 11 times"), wodurch Hermes teils von vorn ansetzte.
- **Musikgenerierung + Sonos-Wiedergabe**: "Installiere ACE-Step zur Musikgenerierung, generiere ein Lied über fliegende Oktopusse und spiel das auf meiner Sonos-Box ab" — ohne weitere Detailangaben fand Hermes die Sonos-Box im Netzwerk und erledigte die komplette Kette selbstständig.
- **Browser-Spiele selbst gecodet**: ein Schneemann-Shooter ("Warmwasser-Schneemänner zum Schmelzen bringen") und ein "3003 Cyber Run"-Autospiel; Soundeffekte dafür lokal generiert mit einem im Transkript unklar wiedergegebenen Tool ("Hardmula", vermutlich Whisper-Fehlhörung eines realen Audio-Tools), ohne dass Keno das Tool selbst installiert hatte.
- **Desktop-Wallpaper generieren und setzen**: Bildgenerierung lokal über ComfyUI + das Bildmodell Flux (z. B. ein Oktopus-Motiv), automatisches Setzen als Hintergrund — inkl. sichtbarem Gefrickel mit KDE/Wayland-Eigenheiten.
- **Desktop-Umgebung wechseln** (KDE → Cosmic) auf CachyOS — lief laut Keno "nur so halb gut", am Ende aber erfolgreich.
- **Hannover-Sehenswürdigkeiten-Liste**: Hermes liefert 20 kuriose "Geheimtipps" für Hannover (u. a. "Leibnizens letzter Hausschuh", "Hannovers erste Telefonzelle in einer Hauswand", "Das grüne Herz" aus recycelten Fahrrädern). **Keno bestätigt im Video selbst explizit, dass jeder einzelne Punkt zu 100 % halluziniert ist** — bewusst als unterhaltsames Negativbeispiel für die Halluzinationsneigung kleiner lokaler Modelle ohne Internetzugriff gezeigt.
- **Sprachgefühl schwächer als bei großen Cloud-Modellen**: Anekdote, bei der Hermes/Qwen eine unbeholfene Formulierung ("timings sie selbst") mit "das war schwul formuliert" kommentiert (regionaler/generationstypischer Slang für "umständlich/schlecht", von Keno direkt hinterfragt: "wie schwul?") — vom Modell selbst korrigiert zu "schlecht ausgedrückt". Zeigt vor allem: kleinere lokale Modelle kommunizieren merklich unnatürlicher als große Cloud-Modelle.

Hardware- und Modellwahl

- **Sweet Spot laut Keno**: Qwen3.6, 27 Mrd. Parameter, 4-Bit-Quantisierung (Gewichte ca. 17 GB). **Per Websuche bestätigt**: Qwen3.6-27B ist ein am 22. April 2026 von Alibabas Qwen-Team veröffentlichtes, dichtes ("dense") Open-Weight-Modell unter Apache-2.0-Lizenz, das laut Herstellerangaben auf mehreren Coding-/Agenten-Benchmarks sogar größere MoE-Modelle (397B Parameter) übertrifft — passt zur im Video gezeigten Hugging-Face-Modellseite (Lizenz, Downloadzahlen, "quantized_by: Unsloth").

- Getestet auf drei Rechnern: Framework Desktop (128 GB Unified Memory, AMD Strix Halo/Ryzen AI Max+ 395), Gaming-PC mit RTX 4090, MacBook Air M2 (24 GB Unified Memory). Qwen lief dabei vom RTX-4090-PC (der bei ihm zufällig unter Windows lief) über Netzwerk zum Linux-Hermes-Rechner — "Linux wird von Windows gesurft".
- Faustregel: ca. 24 GB schneller Speicher nötig (idealerweise GPU-Speicher) für Modell + Kontext + Puffer; läuft auch auf 32 GB normalem DDR5-RAM, dann aber "extrem lahm". Auf dem MacBook Air M2 nur mit max. 16K Kontext praktikabel — für Hermes zu wenig (Minimum laut Keno ca. 64K, besser 100K+, bis hin zum von ihm genannten Qwen3.6-Maximum).
- **Eigener Benchmark (llama-bench/llama.cpp)** — konkrete, im Video als Screenshot gezeigte Zahlen:

Maschine	Prompt-Verarbeitung (pp512)	Token-Generierung (tg128)
PC mit RTX 4090 (24 GB VRAM + 128 GB DDR5)	2.985,7 t/s	47,2 t/s
Framework Desktop / Strix Halo (Ryzen AI Max+ 395, 128 GB unified)	364,0 t/s	12,2 t/s
MacBook Air M2 (24 GB unified)	41,2 t/s	3,6 t/s

Prompt-Verarbeitung ist rechenlimitiert (RTX-4090-Vorsprung bis 72×), Token-Generierung ist speicherbandbreitenlimitiert (Vorsprung schrumpft auf 3,9–13×). Wichtiger Nebenaspekt, den Keno explizit nennt: die RTX-4090-Maschine zieht im LLM-Betrieb über 500 Watt, der Framework Desktop nur ca. 140 Watt.

- **Praxis-Einstieg:** Ollama installieren → `ollama` auf der Kommandozeile → "Launch Hermes Agent (install)" → als Provider Qwen3.6 wählen (nicht die von Ollama beworbenen Cloud-Abos) — laut Keno "quick & dirty", explizit NICHT der beste Weg, aber der einfachste Einstieg. Für ernsthafte Setups installiert er llama.cpp lieber über einen Coding-Agenten (Claude Code/Codex, alternativ auch GLM 5.2) und lässt diesen automatisch passende Modelle/Quantisierungen recherchieren und gegeneinander benchmarken.
- Empfohlene GGUF-Variante laut "Mainstream-Konsens": UD-Q4_K_XL mit MTP (Multi-Token Prediction, laut im Video gezeigtem Unsloth-Blogpost ca. 1,5–2× schnellere Inferenz ohne Genauigkeitsverlust) — passt inkl. Kontext in 24 GB VRAM. Für multimodale Bildfähigkeiten zusätzlich MMPROJ-Datei von Hugging Face nötig.
- Kurzer Exkurs zu Googles **Gemma 4** (Variante 26B-A4B) auf einer neuen Valve Steam Machine (8 GB GPU + 16 GB RAM) — lief, aber sehr langsam, da nicht komplett in den GPU-Speicher passte; sprachlich etwas besser als Qwen, bei Computerbedienung/Coding aber schlechter — deshalb Fokus im Video auf Qwen.

Für den technischen Team-/Gruppenleiter

- Konkrete, aktuelle Hardware-Dimensionierungsregel für lokale Agentic-AI-Pilotprojekte: ~24 GB schneller GPU-Speicher als Einstiegspunkt für ein praxistaugliches Modell (Qwen3.6-27B, Q4) mit

ausreichend Kontext für agentische Workloads (min. 64K, besser 100K+ Token).

- Klare, direkt in Beschaffungs-/Energiekostenentscheidungen einfließende Zahl: RTX-4090-Setup >500 W vs. Strix-Halo-Mini-PC ~140 W im Dauerbetrieb bei gleichzeitig deutlich geringerem Geschwindigkeitsvorteil bei der Token-Generierung (3,9–13×) als bei der Prompt-Verarbeitung (bis 72×) — relevant für die Frage "eigener Server vs. Mini-PC" je nach Workload-Profil (viele lange Prompts vs. viel Chat-Antwortlänge).
- Praktischer Hinweis, lokale LLM-Serving-Infrastruktur (llama.cpp-Setup, Modell-/Quantisierungswahl) über einen Coding-Agenten recherchieren und benchmarken zu lassen statt manuell — spart Einarbeitungszeit bei einem naturgemäß schnell veraltenden Themenfeld.
- Deutliche, wiederholte Sicherheitswarnung zu vollzugriffsfähigen Agentensystemen: nur auf Systemen ohne kritische Daten einsetzen, Prompt-Injection-Risiko ernst nehmen — direkt übertragbar auf die Frage, ob/wie man solche Agenten im eigenen Team pilotiert (z. B. isolierte Testsysteme statt Produktivumgebung).
- Lokale KI als Compliance-/Datenschutz-Hebel: firmeninterne Workflows (im Video am Beispiel eines Schulungs-/Zertifizierungstests gezeigt) lassen sich ohne Datenabfluss an US-Cloud-Anbieter bearbeiten — relevant für Teams mit EU-Datenresidenz-Anforderungen oder Zertifizierungsaufgaben, die Cloud-KI ausschließen.
- Ehrliche Grenze, die der Host selbst mehrfach benennt: kleine lokale Modelle sind noch fehleranfälliger/halluzinationsanfälliger und kommunikativ schwächer als Top-Cloud-Modelle — wichtiges Erwartungsmanagement, bevor man "lokal statt Cloud" im Team als generelle Strategie vorschlägt.

Werblicher Teil

Ca. 1:56–2:56: NordVPN-Sponsoring (Antivirus-Suite inkl. Darknet-Monitor, Rabattcode "CT3003" für vier Zusatzmonate, 30-Tage-Geld-zurück-Garantie) — im Video klar als Werbung gekennzeichnet. Am Ende Hinweis auf zweiwöchige Sommerpause von c't 3003/Podcast "c't 4004" und Werbung für den kostenlosen Newsletter "c't 3003 Hype".

Kernbotschaft

Keno demonstriert live und mit physisch abgezogenem Internetkabel, dass die Kombination aus dem Open-Source-Agenten Hermes Agent (Nous Research) und dem lokalen 27-Milliarden-Parameter-Modell Qwen3.6 inzwischen praxistaugliche agentische KI auf bezahlbarer, aber nicht billiger Consumer-Hardware ermöglicht — von Musikgenerierung über Smart-Home-Steuerung bis zu selbstgecodeten Spielen, alles ohne Cloud-Anbindung des Sprachmodells. Er ordnet Hermes im direkten Vergleich zum bekannteren OpenClaw ein (autonom, token-sparsamer, von Anfang an sicherheitsbewusster konzipiert) und liefert einen ungewöhnlich detaillierten technischen Leitfaden zu Hardwareanforderungen, Quantisierung und eigenen Benchmark-Zahlen (RTX 4090 schlägt Strix-Halo-Mini-PC und MacBook Air M2 deutlich, allerdings bei auch deutlich höherem Stromverbrauch). Gleichzeitig bleibt er trotz des reißerischen Titels ungewöhnlich ehrlich: Das Setup ist noch "Rabbit-Hole"-komplex, kleine lokale Modelle

halluzinieren nachweislich (100 % erfundene Hannover-"Sehenswürdigkeiten" als Negativbeispiel) und kommunizieren merklich schlechter als Spitzen-Cloud-Modelle — für den Massenmarkt ist das noch nichts, wohl aber für alle, die aus Datenschutz-, Zensur- oder Zuverlässigkeitsgründen (Stichwort Fable-5-Exportkontroll-Sperre) unabhängig von US-Cloud-Anbietern experimentieren wollen.

Themen-Tags

Hermes Agent, Nous Research, Qwen3.6-27B, OpenClaw, Peter Steinberger, Lokale KI, llama.cpp, Ollama, GGUF-Quantisierung, RTX 4090, Strix Halo/Framework Desktop, MacBook Air M2, Prompt Injection, Agentic AI, c't 3003, Sonos, ComfyUI, Telegram-Bot, Gemma 4, Valve Steam Machine

Zu prüfen

- **Peter Steinberger/OpenAI-Wechsel und OpenClaw-Foundation-Status:** per WebSearch bestätigt (TechCrunch, Forbes, euronews, alternativeto.net — Steinberger wechselte im Februar 2026 zu OpenAI, OpenClaw wurde laut diesen Quellen in eine von OpenAI unterstützte Stiftung überführt und bleibt Open Source; Steinbergers österreichische Herkunft ebenfalls bestätigt).
- **Qwen3.6-27B Existenz/Specs/Lizenz:** per WebSearch bestätigt (MarkTechPost, Alibaba-Cloud-Blog, offizieller Qwen-Blog — Release 22. April 2026, dense 27B-Modell, Apache-2.0-Lizenz, laut Hersteller-Benchmarks Übertreffen größerer MoE-Modelle bei Coding-/Agenten-Aufgaben).
- **Nous Research als Entwickler von Hermes Agent:** nicht erneut per Websuche geprüft, aber bereits in mehreren anderen Repo-Notizen unabhängig bestätigt (siehe [video-summary-tK9C3Skskws.md](#), [video-summary-8NSyl-npJCU.md](#)) — konsistent mit den Angaben in diesem Video.
- **Cross-Referenz zu [video-summary- Z8W21qUCjo.md](#):** dort wurden "Hermes" und "OpenClaw" bei einem anderen Video nur akustisch erwähnt und ausdrücklich als "nicht per Websuche verifiziert, könnten Whisper-Fehltranskriptionen sein" markiert. **Dieses Video löst die damalige offene Frage auf:** Hermes Agent und OpenClaw sind real existierende, konkurrierende lokale Agentensysteme, keine Fehltranskriptionen.
- **Cross-Referenz zu [lokale-ki.md](#):** ergänzt die dortige Übersicht (Odysseus + Gemma als Beispiel) um ein aktuelleres, deutlich detaillierteres Beispiel (Hermes + Qwen3.6 mit konkreten Hardware-/Benchmark-Angaben) — kein Widerspruch, eher Vertiefung.
- **Cross-Referenz zu [video-summary- Z8W21qUCjo.md](#)** (Hardware-Benchmark-Serie DGX Spark/Strix Halo/Mac): dortige Strix-Halo-Zahlen (339,87 t/s pp / 34,13 t/s tg, anderes Modell/Setup) sind nicht direkt mit den hier gezeigten Strix-Halo-Zahlen (364,0 pp / 12,2 tg) vergleichbar — unterschiedliche Modelle, Quantisierungen und Benchmark-Parameter. Kein Widerspruch, aber auch nicht kreuzvalidierbar; auffällig ist vor allem die deutlich niedrigere tg-Zahl hier, könnte am größeren/dichterem Modell (27B dense vs. dort vermutlich kleinere/andere Modelle) liegen.
- **Tool-Name "Hardmula"** für die lokale Soundeffekt-Generierung: Whisper-Transkript unklar, im Frame nicht lesbar/nicht gezeigt — welches reale Tool gemeint ist, wurde nicht identifiziert.

- Die Detailaussage zu OpenClaws interner Technik (ca. Minute 6, Transkript "Cinema-Modell, ONE-WORD-Nexus-Scritten, JavaScript-Geschmacksschrift") ist eine erkennbar unklare Whisper-Transkription — der genaue technische Sachverhalt bleibt offen und wurde in der Tabelle entsprechend vorsichtig/vage wiedergegeben statt spekulativ interpretiert.
- Die 20 "Hannover-Sehenswürdigkeiten" sind laut Video selbst zu 100 % Halluzinationen — bewusst nicht als Fakten übernommen, sondern nur als Demonstrationsbeispiel referenziert.
- Kontextfenster-Maximum von Qwen3.6: Transkript nennt "226.144" Token, was zahlenmäßig ungewöhnlich wirkt (kein typischer Zweierpotenz-Wert). Ein separat im Video gezeigter Frame nennt für die verwandte Qwen3.6-35B-A3B-Variante "262k Kontext (bis 1M erweiterbar)" — $262.144 = 2^{18}$ ist ein typischer LLM-Kontextfenster-Wert. Spricht dafür, dass "226.144" ein Whisper-Zahlendreher ist, aber nicht abschließend im Frame zur 27B-Variante selbst bestätigt — mit Vorsicht zu genießen.
- Eigene Benchmark-Zahlen (RTX 4090/Strix Halo/MacBook Air M2, Stromverbrauchsangaben 500 W/140 W) sind Kenos eigene Messungen mit llama-bench, im Video als Screenshot gezeigt (Parameter `-fa 1 -ngl 99`, MacBook zusätzlich `-ub 32`) — nicht unabhängig nachgestellt, aber methodisch nachvollziehbar dokumentiert.
- Community-Zahlen/Empfehlungen zu weiteren Modellen (Qwen3-Coder-Next, MiniMax-M2.5, GLM-5.1/5.2, Kimi-Linear-480-A3B, MiniMax-M3) stammen aus einem im Video gezeigten Recherche-Chat mit einem Coding-Agenten (Claude Code) — nicht unabhängig gegengecheckt, wirken aber intern konsistent und technisch plausibel begründet.

Quellen der Plausibilitätschecks

-
- [TechCrunch — OpenClaw creator Peter Steinberger joins OpenAI](#)
 - [Forbes — OpenAI Hires OpenClaw Creator Peter Steinberger And Sets Up Foundation](#)
 - [euronews — Austrian creator of viral OpenClaw joins OpenAI](#)
 - [MarkTechPost — Alibaba Qwen Team Releases Qwen3.6-27B](#)
 - [Alibaba Cloud Community — Qwen3.6-27B: Flagship-Level Coding in a 27B Dense Model](#)
 - [Qwen Blog — Qwen3.6-27B](#)

Hinweis zum Ablauf: Native YouTube-Untertitel scheiterten wiederholt mit HTTP 429 (auch nach mehreren Wartezeiten/Retries). Da der einzelne Replicate-Whisper-Aufruf für die volle 29-Minuten-Datei nach 6 Minuten Poll-Timeout abbrach, wurde die Audiospur eigenständig in 7 Chunks à 280s zerlegt und einzeln über Replicate/Whisper transkribiert (453 Segmente gesamt, Zeitstempel korrekt versetzt). Alle 80 extrahierten Frames wurden gesichtet; bei diesem stark bildschirmlastigen Video (Terminal-Screenshots, Benchmark-Tabellen, Modell-Metadaten, Telegram-Chats) lieferten Frames und Transkript zusammen ein deutlich vollständigeres Bild als jede Quelle allein.

Quelle: video-summary-Ne2UH682x9I.md